

# 资源约束下双语铁路职业教育的 知识增强型大语言模型

## 摘要

**研究背景。**中国高铁技术的国际化应用不断扩大，使双语知识传递与职业培训需求持续增长。现有铁路大语言模型研究往往分别考察领域适配或检索增强生成，对双语模型适配、治理式检索、证据来源与资源约束部署之间的协同关系缺少联合验证。因此，本研究以知识增强型大语言模型为核心，并构建受约束人工智能智能体系统作为可控的实验与应用环境，面向国际学习者和职业培训学员、铁路技术与服务从业者，以及培训、咨询和管理人员。

**研究方法。**研究构建专家治理的双语铁路语料，并采用按知识对分组的控制策略，隔离训练、验证与留出评估记录。实验比较 Qwen2.5-7B 和 GLM-4-9B 在双语 QLoRA 适配前后的表现，并以 Qwen3-14B 作为参考模型；在留出双语查询上比较 BM25、BGE-M3 密集检索与倒数排名融合混合检索。模型适配采用独立的双语问答评估，并辅以受控的无检索生成与检索增强生成比较。评价指标包括证据 Recall@k、平均倒数排名、Answer F1、配对显著性、证据支持度和单机部署资源使用。

**研究结果。**混合检索在中文和英文上的证据 Recall@5 分别达到 0.715 和 0.708，均高于对应最优单一检索器的 0.690 和 0.685；双语字段索引取得最高的跨语言均衡均值 0.696。Qwen QLoRA 将中文留出问答字符级 F1 从 0.189 提升至 0.398，将英文从 0.437 提升至 0.648，且两项提升经 Holm 校正后仍具有显著性。在混合检索增强生成条件下，其 Answer F1 达到最高的 0.660 和 0.651，高于 Qwen3-14B 参考模型的 0.442 和 0.454。所有被评估生成器条件均在定义的单机资源边界内完成运行。

**研究结论。**将双语参数高效适配与治理式混合检索相结合，可以在资源约束的单机部署条件下提升跨语言证据访问和领域问答表现。该模型研究框架为联合评价模型适配、知识检索与证据治理提供了可迁移的方法，也为双语铁路职业教育和国际从业人员培训提供了可本地控制的技术基础。

**关键词：**双语铁路教育；检索增强生成；QLoRA 适配；Web 信息系统

## 1 引言

中国高铁的发展备受国际瞩目，也带来了双语技术交流和职业培训需求。然而，交流过程中存在语言、术语、来源获取和审核方式差异等问题。铁路职业教育涉及安全关键规章、专业术语和程序性教材知识，学习者和从业人员常需在中文源材料与英文学习支持之间切换。通用大语言模型虽能生成流畅答案，却难以清晰区分已验证知识与无依据生成。因此，系统必须在受控的本地工作流中完成双语知识的获取、治理、检索、呈现和溯源。

目标用户不仅包括学生，也包括铁路职工、教师、培训师、技术顾问和管理人员。系统不能只翻译术语，还应将双语问题连接到合规规章或教学段落，保留来源并显示审核状态。已有研究关注铁路安全、设计、轨道管理、预测性维护、司机建议和交互式培训，但双语访问、证据治理与可复现本地部署仍缺乏综合研究。

本文将有限资源定义为可复现的单工作站约束，具体硬件配置在方法部分说明。

现有研究通常分别评估通用语言模型或检索增强生成。本文工作由四个缺口驱动：第一，双语教育检索很少按查询语言分别评价；第二，专家审核常被描述为预处理，而不是可查询的

治理状态；第三，领域适配往往只在目标任务上评估，翻译退化和引用遵循失败可能被隐藏；第四，“智能体”常在未定义动作边界时使用，部署报告也可能忽略检索质量、可追溯性和单工作站实测成本之间的关系。

本文回答以下研究问题：

- **RQ1:** BM25、pgvector 密集检索和混合融合，对中英文留出铁路问答对的证据等价索引记录检索准确度如何？
- **RQ2:** 不同检索策略如何影响答案重叠和引用格式遵循？仅审批记录的资格限制能否在检索时被执行和审计？
- **RQ3:** 两个翻译方向分别达到怎样的双语翻译质量？在按知识对分组的留出评估下，仅完成部分监督的 QLoRA 如何影响领域问答？

本文有四项贡献。第一，将双语铁路知识库中的审核状态、来源元数据、语言变体和修订历史设计为可查询信息，而不是压平为匿名向量集合。第二，构建受约束的 PostgreSQL/pgvector 智能体工作流，将词法检索、多语言密集检索和带证据标签的本地生成结合起来，同时保持检索策略由用户或运维人员配置。第三，提出按知识对分组的协议，分别报告中英文检索、问答和翻译结果，并采用记录层面的划分控制。第四，在定义的单工作站上联合评估适配、检索和推理，呈现引用遵循、双向翻译和运行时资源使用中的提升与失败。

## 2 相关工作

### 2.1 知识增强型 Web 信息系统

Web 信息系统日益结合结构化数据管理、语义访问和生成式界面。《International Journal of Web Information Systems》中的研究表明，应整合知识表示、流程状态和面向用户的任务，而不是把它们视为彼此孤立的技术组件 (Hübscher et al., 2021)。检索增强生成 (RAG) 在参数化生成与外部维护的证据集合之间提供了实用分离 (Lewis et al., 2020)。这对机构知识系统很重要，因为源记录可以修订，而无需重新训练生成器。但这种分离并不保证生成忠实：检索可能遗漏相关证据，生成器也可能错误表述已正确检索的材料。因此，本文将检索、答案重叠、证据支持和引用格式行为作为不同结果分别评估。

检索层结合互补的词法和语义信号。BM25 仍是精确领域术语的高效词法基线 (Robertson and Zaragoza, 2009)，倒数排名融合则可以在不要求分数尺度直接可比的情况下合并排序 (Cormack et al., 2009)。PostgreSQL 和 pgvector 将向量检索置于受治理的关系元数据旁边，使审批状态和留出划分边界能够在查询中应用，而不是在生成后再处理。这使知识治理成为可执行的信息系统设计的一部分。

这一点使本文系统区别于只面向文档的 RAG 演示。Web 信息系统必须在摄取、审核、检索和呈现过程中维护记录身份与生命周期状态。本文中，向量表示是附着于受治理记录的派生数据，而不是事实来源。删除、修订或暂缓一条记录可以改变其检索资格，而无需重建整个应用，也不依赖提示词来强制治理。

### 2.2 教育领域的检索增强生成

生成式人工智能可以支持解释、反馈和学习资源访问，但教育研究也指出了事实可靠性、学习者过度依赖和来源不透明等风险 (Kasneci et al., 2023; UNESCO, 2023)。法律文档自动问答的综述证据同样表明，专业大语言模型服务需要协调数据处理、模型调整和应用框架，而

不能只替换模型 (Yang et al., 2024)。教育 RAG 通过以课程或机构材料为条件, 部分缓解了这一问题。然而, 许多演示仍只报告汇总答案分数, 没有分离检索失败、语言影响或部署成本。对于国际职业教育, 这种汇总尤其不合适, 因为英文问题可能需要从中文规章或教材中获取证据。因此, 本文分别报告中文和英文的检索与生成结果, 并在每个检索结果中保留文档级来源。

铁路应用说明了这种分离的必要性。RSChat 面向铁路安全问答 (Li et al., 2024), 已有基于大语言模型的人机交互培训助手在铁路调度、教育和职业培训中得到评估 (Li et al., 2025); 也有研究提出面向列车司机建议和应急响应生成的领域系统 (Luo et al., 2025; Huang et al., 2026)。这些研究说明了领域知识和培训支持的价值, 但本文的运行目标有所不同: 双语用户可能用英语提出概念, 需要中文来源证据, 并要求来源和审核状态可见。因此, 本文将跨语言访问、治理和明确的单工作站部署结合起来评估。

## 2.3 受约束智能体与资源感知部署

经典智能体研究把智能体与情境化行动和一定程度的自主性联系起来 (Wooldridge and Jennings, 1995), 近期大语言模型智能体综述则把规划、记忆、工具使用和环境行动描述为常见但并非固定的组成部分 (Xi et al., 2025)。本文以更窄的操作性含义使用“受约束工作流智能体”一词。其固定动作空间包括: 路由中英文语言字段, 调用由用户或运维人员选择的 BM25、向量或混合检索器, 强制执行记录资格, 组装编号证据, 调用本地生成器, 并返回确定性的无证据或检索回退。它不设定开放式目标, 不浏览外部 Web, 不选择任意工具, 也不能在未经人工审批时修改知识库。检索模式与 top- $k$  仍由用户或运维人员配置。该边界使本文服务区别于自主通用智能体, 并使每项动作可审计。

资源感知评估也是这一边界的一部分。高效人工智能研究主张, 计算成本与效率应和预测质量共同报告 (Schwartz et al., 2020)。对于本地智能体, 小型适配器文件或较低的可训练参数占比都不能证明推理内存或时延较低。因此, 本文把明确的工作站配置、峰值预留 GPU 内存、生成速度和时延作为可复现性条件, 而不依据参数数量推断可负担性。

## 2.4 双语领域适配与评估

双语领域系统既需要跨语言检索, 也需要受控生成。BGE-M3 支持多语言密集检索, 本文选用它为中文和英文知识字段提供共享嵌入空间 (Chen et al., 2024)。本文不预设密集相似度优于词法匹配, 而是在融合前分别比较两种方法。

参数高效适配是领域专门化的另一种机制。QLoRA 通过冻结的 4-bit 量化基础模型训练低秩适配器, 在保留任务适配能力的同时降低内存需求 (Dettmers et al., 2023)。本文使用仅完成部分的掩码, 使提示词不参与训练损失; 共享知识对标识符的双语变体被放入同一划分。翻译按方向评估, 因为中译英和英译中的分数不可直接互换; 术语翻译与完整句子翻译也分别保留。

PEFT 方法可以减少可训练参数, 但不保证部署后的系统更好 (Ding et al., 2023; Wang et al., 2025)。资源受限训练仍对量化、序列长度、优化器状态和模型特定目标模块敏感 (Lv et al., 2024)。此外, 任务适配可能提升答案重叠, 却损害事实性、指令遵循或无关能力 (Tian et al., 2024; Barnett et al., 2024)。因此, 本文采用前后对比设计, 除领域问答外, 还报告通用能力检查、引用行为和内存使用。

因此, 研究前沿正在从证明领域大语言模型能够生成答案, 转向验证知识增强型工作流能否在有限计算和内存条件下完成本地适配、治理与服务。该系统视角要求联合报告模型质量、检索质量、可追溯性、时延和峰值内存; 参数高效本身并不等同于可部署结果 (Ding et al., 2023; Lv et al., 2024; Wang et al., 2025)。

领域翻译进一步带来汇总评估风险。既有工作表明，微调效果取决于训练方向、领域组成和数据量 (Hu et al., 2024; Vieira et al., 2024; Zheng et al., 2024)。因此，本文不把单一双语均值解释为稳健翻译的证据，而是分别报告两个方向上的术语和句子任务，并保留空输出或错误语言输出作为失败，而不将它们静默删除。

### 3 系统设计与研究方法

#### 3.1 应用场景与需求

目标用户分为四类角色。第一类为学习者，包括国际学生、职业技能培训学员和需要双语支持的中文学习者；第二类为铁路从业者，包括跨境铁路环境中的铁路服务人员、当地在职职工和技术骨干；第三类为教育与咨询人员，包括职业院校教师、企业培训师和技术顾问；第四类为管理与系统运维人员，包括培训管理者和平台管理员。这四类角色对应三个访问群组：学习者和铁路从业者使用双语门户；教师、培训师和技术顾问使用审核控制台；管理者和管理员使用运维控制台。系统必须返回简洁答案，展示编号证据，保留文档元数据，并在不要求云端推理的情况下运行于定义的工作站。

图 1 展示双语铁路问答的检索与 QLoRA 工作流。上方路径涵盖受治理输入、检索、证据条件化生成和评估；下方路径展示冻结基础模型上的仅答案监督 QLoRA 训练。图示表示信息流和训练范围，不代表新的模型架构。

图 1 下方分支将离线仅答案监督的 QLoRA 训练与在线检索、评估分开。评估面板区分答案重叠、引用遵循、翻译质量、证据支持和资源开销；这些指标相互独立。

#### 3.2 专家治理的知识库

知识记录包括中英文问题和答案、证据、原文、源文档、章节、页码、任务类型、质量标记、审核状态和修订历史。PostgreSQL 存储受治理记录，pgvector 存储 1,024 维 BGE-M3 嵌入。生产索引排除被分配到留出测试划分的确切记录。

知识来源包括铁路术语、运营与安全规章，以及职业教材或概念材料。摄取过程尽可能保留源文档、章节和页码字段。中英文问题和答案被存储在同一逻辑记录的不同字段中，确保语言变体不丢失来源身份。嵌入通过记录标识符和模型版本关联，可以在不改变已审核文本的情况下重建。标记为 `rejected`、`needs_revision` 或属于冻结 RAG 测试的记录，在排序前排除。这个数据库层面的决定防止确切测试记录通过 BM25 或向量检索泄漏，但不能证明所有其他记录中都不存在语义等价证据。因此，检索结果被定义为证据等价召回，而不是确切记录召回。

三位作者共同构建并检查知识库以及训练和评估数据集；其综合专长覆盖铁路职业教育、国际职业教育、环境与数据分析，以及软件和多模态语言模型工程。然而，发布的治理审计中只有两个不同的审核者标识符。因此，本文报告两个可审计的审核账户，不把这些标识符之外的作者层面检查重新解释为第三次独立审核。由于这是作者主导的治理程序，而非独立的评审者间研究，本文不报告评审者间一致性统计，也不声称存在外部专家共识。`approved` 仅被分析为可执行的资格状态。




图 1: 双语铁路问答的检索与 QLoRA 工作流。上方路径涵盖受治理输入、检索、证据条件化生成和评估；下方路径展示冻结基础模型上的仅答案监督 QLoRA 训练。图示表示信息流和训练范围，不代表新的模型架构。来源：作者绘制。



### 3.3 检索与答案生成

BM25 对中英文问答字段和证据建立索引。密集检索使用 BGE-M3 对查询进行嵌入，并按向量相似度排列文本块。混合检索使用倒数排名融合合并关键词和密集排序。Approved-Only 条件将审核状态作为数据库层面的资格过滤器。检索模式与 top- $k$  由用户或运维人员配置，而不是由大语言模型自主选择。检索到的证据被编号，并与要求使用查询语言回答和引用证据标签的指令一起提供给本地生成器。

按照 Cormack 等人 (Cormack et al., 2009) 的定义，候选文档  $d$  的倒数排名融合分数为：

$$\text{RRF}(d) = \sum_{r \in \{\text{BM25}, \text{vector}\}} \frac{1}{k_0 + \text{rank}_r(d)}. \quad (1)$$

若文档不在某一检索器的候选列表中，则该检索器的贡献为零。每个检索器的候选池固定为 50，传统排名常数为  $k_0 = 60$ ；在改变最终 top- $k$  之前先应用公式。这个受控的 top- $k$  对比只改变提供给生成器的证据量，不改变上游搜索池。密集排序使用 BGE-M3 查询嵌入和 pgvector 距离，词法排序则保留缩写、设备名称和规章编号等精确技术语言。每个返回的证据对象都包含记录标识符、源文档、任务类型和检索分数。

密集检索的余弦相似度定义为：

$$s_{\text{dense}}(q, d) = \frac{\mathbf{e}_q^\top \mathbf{e}_d}{\|\mathbf{e}_q\|_2 \|\mathbf{e}_d\|_2}. \quad (2)$$

仅答案监督的适配损失只在答案位置计算。令答案 token 的掩码为 1、提示词 token 的掩码为 0，则：

$$\mathcal{L}_{\text{answer}}(\theta_A) = - \sum_t m_t \sum_t m_t \log p_{\theta_0, \theta_A}(y_t | y_{<t}, x). \quad (3)$$

其中  $\theta_0$  为冻结的 NF4 基础权重， $\theta_A$  为可训练的 LoRA 参数。独立双语问答使用字符级重叠指标；对预测答案  $\hat{y}$  和参考答案  $y$ ，定义为：

$$P = \frac{|\hat{y} \cap y|}{|\hat{y}|}, \quad R = \frac{|\hat{y} \cap y|}{|y|}, \quad F1 = \frac{2PR}{P + R}. \quad (4)$$

配套 Web 系统通过 Vite 客户端与 FastAPI 后端提供知识审核、检索、对话访问和来源证据展示，为本地维护的知识库与生成器提供应用界面。本文的实验比较聚焦检索、模型输出及资源使用，Web 界面本身不构成教育有效性评估。生成答案被描述为证据条件化输出，因为引用格式遵循和语义支持需要分开评估。

### 3.4 双语 QLoRA 适配

适配数据集只由已审批记录生成，并按知识对标识符、任务类型和源文档划分。同一知识项的中英文变体被分配到同一分区。当前冻结的 80/10/10 语料包含 12,178 个训练、1,524 个验证和 1,526 个测试样本，按语言均衡，所有分区之间不存在知识对标识符重叠。为 RAG 评估保留的 120 个规章项目被强制放入测试分区，且从未用于训练。损失只在答案 token 上计算，所有提示词标签都以 Minus 100 屏蔽。

Qwen2.5-7B-Instruct 和 GLM-4-9B-Chat-HF 构成适配矩阵，其架构和后训练谱系记录于官方技术报告 (Qwen Team, 2024; GLM Team, 2024)。二者均在目标 GPU 上以 NF4 量化和 PEFT 适配器加载。Qwen 暴露独立的 Gate Projection 和 Up Projection 模块，而 GLM 使用融合的 Gate-Up Projection，因此需要模型特定的目标列表。正式 Rank 64 配置训练了 161,480,704 个 Qwen 参数和 190,382,080 个 GLM 参数，分别占量化训练过程可见参数的

3.58% 和 3.45%。Qwen3-14B 仅作为未适配参考生成器保留，并对应 Qwen3 技术报告 (Qwen Team, 2025)。

两次运行均使用 LoRA Rank 64、Alpha 16、Dropout 0.05、Learning Rate 2e-4、Maximum Sequence Length 1,024 和一个 epoch。单设备 Batch Size 为 1，Gradient Accumulation Steps 为 16，Warm-Up Ratio 为 0.03。实验配置固定随机种子 42。生成使用贪心解码，Temperature 为 0、Top-P 为 1，并设置任务相关的输出上限。仅完成部分监督将每个提示词 token 设为 Minus 100，因此训练优化的是答案序列，而不是让模型复述指令。这个选择需要通过实验检验，并不预设会改善所有下游行为。

### 3.5 评估设计

检索条件包括 BM25、向量、混合和审批混合。指标包括证据等价 Recall@1/3/5、MRR 和平均时延。正式生成器矩阵固定使用无检索、BM25-RAG 和审批混合 RAG，使五个生成器接收相同的缓存上下文。自动指标包括 Answer F1、参考答案包含率、引用格式覆盖率、引用缺失率和端到端时延。引用指标只作为指令遵循指标，不作为证据蕴含或事实幻觉指标。翻译使用 SacreBLEU、chrF++ 和 COMET (Unbabel/wmt22-comet-da)，分别报告中译英和英译中的术语与句子任务。该多维协议遵循 LLM 评估应分离任务能力、稳健性和部署行为，而不依赖单一汇总分数的原则 (Chang et al., 2024)。

当前  $k$  个候选中至少有一个满足冻结匹配规则时，证据等价 Recall@ $k$  为 1。匹配规则包括：记录标识符相同；归一化后的标准证据与候选证据在任一方向上存在包含关系；或者源文档相同且标准答案包含在候选证据中。由于确切 RAG 测试记录被排除在生产索引之外，观察到的命中通常来自后两项证据等价条件，而不是记录身份相同。MRR 是第一个此类匹配的倒数排名均值。独立双语问答评估在两种语言中均使用字符级 F1：答案归一化并去除空白后，按字符多重集重叠计算精确率和召回率。配对问答检验与图 5 的双语均值均使用同一指标。RAG 评估则对中文单字和小写拉丁字母/数字词元计算重叠 F1。两种 F1 分别在各自评估设置内报告，不作为可互换的绝对分数。独立问答的参考答案包含率为二值指标，表示归一化参考答案是否包含于预测中；RAG 保存的参考答案包含分数在空白归一化后的参考答案被预测包含时为 1，否则回退为 RAG F1，预测或参考为空时为 0。因此，后者是连续包含分数，而非二值包含率。引用格式覆盖率只记录所要求的证据标签语法是否出现，其补集报告为引用缺失率。这些指标均不检验声明-证据蕴含或事实幻觉。

所有核心对比使用配对样本。均值指标配有 2,000 次重采样 bootstrap 的 95% 置信区间。原始模型与 QLoRA 的对比使用双侧配对 Wilcoxon 检验、配对效应量 Cohen's  $d_z$ ，并在分析配置所记录的预先指定比较族上进行 Holm 校正。探索性错误类别单独报告，不作为验证性假设检验。效率测量使用 30 个中文短问题、30 个英文短问题和 30 个规章导向长上下文问题；每个模型条件先预热一次，再测量三次。

三项自动系统检查扩展了主要协议，但没有引入新的人工标签。第一，在相同的 800 个查询和 512 token 的 BGE-M3 窗口上比较仅源字段、中文字段、英文字段和双语字段索引。第二，将 8,000 个 RAG 答案切分为声明，使用 BGE-M3 余弦相似度，在预先指定的 0.45 阈值下估计其相对于全部检索证据和明确引用证据的语义支持；这只是支持代理指标，而不是文本蕴含或专家正确性。第三，审计不可变审核事件和修改前状态快照，检查动作与变更字段覆盖。每个生成器条件的资源行为来自单独的 270 次推理测量实验。

### 3.6 实现与可复现性

应用使用基于 Vite 的 Web 客户端、FastAPI 后端，以及 PostgreSQL 16.14 和 pgvector 0.8.4。实验在 Linux 上运行，硬件为一块 NVIDIA GeForce RTX 3090 (24,576 MiB) 和 32

GB 主机内存，软件包括 Python 3.11.15、PyTorch 2.11.0、Transformers 5.12.1、PEFT 0.18.1 和 bitsandbytes 0.49.2。被评估路径不需要多 GPU 或云端推理资源。这是本文可复现的单工作站约束及其相对低成本的系统配置；本文不作采购价格或总体成本声明。Qwen2.5-7B-Instruct、GLM-4-9B-Chat-HF 和 BGE-M3 通过冻结清单中的模型版本固定。COMET 使用固定版本的 Unbabel/wmt22-comet-da 检查点。输入数据集、配置、生成表格和最终分析资产均以 SHA-256 哈希记录。表 I 汇总正式实现与实验环境。

| 表 I: 正式实现与实验环境 |                                                         |
|----------------|---------------------------------------------------------|
| 组件             | 正式设置                                                    |
| 数据库            | PostgreSQL 16.14; pgvector 0.8.4                        |
| 嵌入             | BAAI/bge-m3; 1,024 维                                    |
| 适配生成器          | Qwen2.5-7B-Instruct; GLM-4-9B-Chat-HF                   |
| 参考生成器          | 通过 Ollama 0.19.0 使用 Qwen3-14B                           |
| 训练             | NF4 QLoRA; rank 64; 一个 epoch; 种子 42                     |
| 硬件边界           | 单块 RTX 3090 24 GB; 32 GB RAM; 无多 GPU 或必需云端推理            |
| 统计分析           | 2,000 次 bootstrap; 配对 Wilcoxon; Cohen's $d_z$ ; Holm 校正 |

代码将测试集构建、嵌入、检索评估、生成器评估、适配和报告导出分离，防止分析脚本静默改变生产索引或训练划分。正式 RAG 矩阵中的生成器复用缓存检索上下文，因此模型比较接收相同证据。清单在冻结时记录 Git 状态和每个输入的哈希，以支持结果重建和跨运行的一致比较。

默认情况下，生产嵌入加载仅使用本地文件，防止不可用的模型注册表成为隐藏的运行时依赖。真实审核和问答视图通过运行中的 Vite 与 FastAPI 服务渲染，而不是重构为模拟界面。固定环境、模型版本、划分统计和资产哈希支持重建所报告的单工作站对比。

## 4 结果

### 4.1 知识库组成

数据库包含 37,661 条已审批记录和 37,109 条完整双语记录。冻结正式 RAG 测试后，37,261 个已审批非测试知识块具有 BGE-M3 嵌入。QLoRA 测试分区包含来自四个源文档的 763 个知识对。正式跨来源 RAG 集从该分区中选取 400 个知识对和 800 个按语言划分的查询，其中包括 150 个规章、127 个术语和 123 个教材/概念知识对，覆盖 17 种任务类型。早期 120 对规章试验是该正式集合的子集，仍保留在可复现产物中，但不再作为额外样本报告于主要结果。

### 4.2 正式跨来源双语检索

表 II 报告正式证据等价检索对比。BM25 对英文术语查询尤其具有竞争力，而密集检索在本评估中记录了更高的中文证据召回。在每个最终截断点都固定 RRF 候选池为 50 时，混合融合在两种语言上都取得最高证据 Recall@5，但时延约为 BM25 的三倍。在这一受控评估中，将最终截断点从 3 增加到 8，使混合证据召回率从中文 0.675、英文 0.668 分别升至 0.743 和 0.723，而平均检索时延基本不变（图 2）。仅审批与未过滤混合结果相同，因为冻结实验中



表 II: 400 个知识对上的正式跨来源证据等价检索

| 检索   | 语言 | 证据 R@1       | 证据 R@3       | 证据 R@5       | MRR          | 平均时延 (ms)   |
|------|----|--------------|--------------|--------------|--------------|-------------|
| BM25 | 中文 | 0.520        | 0.595        | 0.620        | 0.560        | <b>69.5</b> |
| 向量   | 中文 | 0.518        | 0.653        | 0.690        | 0.588        | 134.4       |
| 审批混合 | 中文 | <b>0.570</b> | <b>0.675</b> | <b>0.715</b> | <b>0.628</b> | 217.6       |
| BM25 | 英文 | <b>0.570</b> | <b>0.670</b> | 0.685        | 0.620        | <b>59.0</b> |
| 向量   | 英文 | 0.463        | 0.553        | 0.580        | 0.509        | 134.4       |
| 审批混合 | 英文 | <b>0.570</b> | 0.668        | <b>0.708</b> | <b>0.620</b> | 209.2       |

所有符合资格的索引记录都满足审批条件。这些数值适用于第 3.5 节的匹配规则，不能解释为检索到了已被排除的测试记录本身。




图 2: 不同 top-k 设置下混合检索的证据等价质量与时延。左图为证据 Recall@k, 右图为平均检索时延。

### 4.3 QLoRA 适配与留出问答

两次一个 epoch 的训练均无中断完成。Qwen 训练用时 3,546 秒 (59.1 分钟), 平均训练损失为 0.950, epoch 末验证损失为 0.720, 峰值预留显存为 13.0 GiB; GLM 训练用时 4,571 秒 (76.2 分钟), 平均训练损失为 1.146, epoch 末验证损失为 0.794, 峰值预留显存为 15.0 GiB。相应验证困惑度为 2.05 和 2.21。

图 3 展示日志记录的训练损失曲线, 以及每个模型唯一的 epoch 末验证点。Qwen 和 GLM 最后一次日志记录的训练损失约为 0.700 和 0.791, 不同于前述整个训练过程的平均损失。一个 epoch 的曲线描述优化过程, 不证明模型在延长或重复训练安排下已经收敛。没有进行扩展超参数搜索符合资源受限设计, 但也限制了关于适配器设置全局最优的主张。

在 1,526 个样本的留出双语问答集上, Qwen QLoRA 将中文字符级 F1 从 0.189 (95% CI 0.175–0.204) 提高到 0.398 (0.376–0.422), 英文从 0.437 (0.419–0.455) 提高到 0.648 (0.632–0.664)。GLM 中文从 0.192 提升到 0.410, 英文从 0.498 提升到 0.552。四项配对提升在 Holm 校正后仍显著 (所有调整后 p 值均低于 0.01); Qwen 中英文的 Cohen’s  $d_z$  分别为 0.569 和 0.634, GLM 分别为 0.614 和 0.146。因此, 在这一字符级指标下, Qwen 提供了最强的均衡适配问答结果, 而 GLM 较小的英文效应说明不应合并两种语言。这些样本层面检验不能估计不同训练随机种子之间的变异。

有限的通用能力检查（每个子任务最多 200 个样本）发现，Qwen C-Eval/MMLU 准确率从 0.788/0.739 变为 0.775/0.728，GLM 从 0.675/0.673 变为 0.683/0.679。这些小幅变化不能说明广泛的灾难性遗忘，但受限协议只是回归检查，并非全面通用基准。




图 3: Qwen2.5-7B 和 GLM-4-9B 的仅答案监督 QLoRA 优化过程。曲线表示日志记录的训练损失；菱形表示每个模型唯一的 epoch 末验证点。

#### 4.4 多生成器 RAG 对比

Holm 校正后，审批混合 RAG 在每个生成器和语言上都显著提高了相对于无检索的 Answer F1。对于中文和英文，原始 Qwen 的调整后 p 值为  $1.89e-39$  和  $2.28e-42$ ，原始 GLM 为  $1.13e-22$  和  $9.56e-31$ ，Qwen QLoRA 为  $1.34e-06$  和  $1.41e-11$ ，GLM QLoRA 为  $3.16e-09$  和  $9.37e-03$ ，Qwen3-14B 为  $6.66e-32$  和  $7.58e-29$ 。原始 Qwen 的 F1 在中文从 0.262 升至 0.402，在英文从 0.306 升至 0.440，配对效应量分别为 0.796 和 0.798。Qwen QLoRA 取得最高绝对 RAG F1（中文 0.660、英文 0.651），高于 Qwen3-14B 参考值（0.442、0.454）。但其相对无检索的增量仅为 0.030 和 0.078，而原始 Qwen 为 0.141 和 0.133。BM25 与混合检索的答案质量不存在统一排序：原始 Qwen 的 BM25/混合 F1 在中文为 0.406/0.402，在英文为 0.433/0.439；Qwen QLoRA 则分别为 0.674/0.660 和 0.644/0.651。GLM 和 Qwen3 也出现类似的排序反转。因此，观察到的答案重叠提升取决于适配、检索策略和语言。

可追溯性结果有所不同。原始 Qwen 的引用格式覆盖率在中英文中由 BM25 条件下的 0.543/0.638 变为混合条件下的 0.595/0.643；Qwen3 则由 0.715/0.900 变为 0.788/0.905。相比之下，Qwen QLoRA 在混合条件下仅为 0.000/0.003，GLM 也呈现相同但较弱的适配相关模式。在测试条件下，QLoRA 的答案重叠更强，但对评估目标中使用的引用指令遵循更弱，因此适配模型的引用缺失率接近 1。这是指令遵循失败，而不是实测的事实幻觉率。在实际系统中，Qwen2.5 QLoRA 可作为主要答案质量模型，而在加入引用感知适配之前，原始 Qwen 或 Qwen3 仍是更安全的可追溯性控制。

## 4.5 双向翻译

翻译效果取决于方向和任务。Qwen 的 COMET 在中译英术语上从 0.501 变为 0.509，在英译中句子上从 0.610 变为 0.614；但中译英句子从 0.656 降至 0.599，英译中术语从 0.596 降至 0.485。词汇指标也显示出并非普遍提升：中译英术语 chrF++ 从 10.41 增至 16.69，而句子 chrF++ 从 47.43 降至 31.28。相反的变化说明结果不能概括为单一提升或退化。

图 4 按方向和任务展示适配前后的 COMET 变化。配对柱形在部分条件下升高、在另一些条件下降低，表明结果不能概括为一致提升或退化。

GLM QLoRA 是明显的失败案例。其句子 COMET 在中译英中从 0.667 降至 0.348，在英译中从 0.742 降至 0.343；两个方向的 corpus BLEU 均为 0。自动检查在 2,634 个翻译样本中发现 2,168 个空输出（82.3%）。这一结果不支持“面向问答的仅完成部分适配一般能够改善翻译”的结论。因此，术语和句子翻译应与问答评估分开报告。




图 4: 按方向和任务拆分的 QLoRA 前后 COMET。左图为 Qwen2.5-7B，右图为 GLM-4-9B。

## 4.6 资源使用与自动错误分析

五种部署条件均完成 270 次测量，未出现执行失败或 OOM。显存实测值统一以 GiB ( $2^{30}$  字节) 表示。原始 Qwen 和 GLM 的 PyTorch 峰值预留显存为 5.49 和 6.76 GiB，生成速度为 31.9 和 22.7 token/s；对应 QLoRA 版本为 16.11 和 19.49 GiB，速度为 17.5 和 11.9 token/s。原始模型的峰值实际分配显存分别为 5.35 和 6.48 GiB，对应 QLoRA 版本为 15.40 和 7.20 GiB。预留显存包括缓存分配器的预留空间，不应解释为存活张量占用量或适配器固有开销。通过 Ollama 使用的 Qwen3-14B 峰值 GPU 进程显存为 14.26 GiB，速度为 78.5 token/s；这一显存统计并非 PyTorch 预留显存，跨后端显存和时延比较仅为描述性比较。Qwen 和 GLM 适配器约占 627 和 746 MB。GLM QLoRA 平均时延较低（2.63 秒）是由异常短输出或空输出造成的，并不表示效率更高。所有配置都适合目标 24 GB 工作站；原始 Qwen 的资源成本最低，Qwen QLoRA 在限制内提供最强问答质量。

图 5 展示 Qwen2.5/GLM 原始与 QLoRA 四种条件下，独立问答的双语平均字符级 F1 与生成时延、峰值预留显存之间的关系。质量与资源测量来自各自的评估负载。该图是质量与资源的描述性比较，而不是适配器开销的受控因果估计；图中不包含通过 Ollama 运行的 Qwen3。

自动失败标记为汇总结果提供了额外的描述性对比。在前三个候选中，审批混合检索对中文 32.5% 和英文 33.3% 的查询未返回满足冻结等价规则的证据。原始 Qwen 的“证据命中且答案低重叠”联合事件占全部中文查询的 18.0%、全部英文查询的 4.3%，分母为全部查询

而非仅检索命中的查询；Qwen QLoRA 将其降至 4.0% 和 1.5%，但引用标签缺失率为 100.0% 和 99.8%。图 6 单独汇总独立双语问答及领域/翻译输出中的术语不匹配、答案低重叠、空答案、错误语言标记和过长答案。每根柱形是出现对应标记的模型条件/任务组内比例的均值，不是合并样本后的发生率，也不是前述 RAG 检索与引用统计的绘图。各标记可以同时出现；术语不匹配表示未通过参考答案包含检查，而非专家判定术语错误。




图 5: Qwen2.5/GLM 原始与 QLoRA 四种条件下，独立问答双语平均字符级 F1 与生成时延、峰值预留显存 (GiB) 的关系。左图为平均生成时延；右图为 PyTorch 预留显存。质量与资源在不同负载上测量。




图 6: 独立双语问答及领域/翻译输出标记。柱形表示出现对应标记的模型条件/任务组内比例的均值，不是合并样本后的发生率。各标记不互斥；RAG 检索遗漏与引用缺失另见正文。

#### 4.7 索引、证据支持与治理验证

表 III 报告三项补充信息系统验证。字段对比显示了不同的语言特定结果：英文专用混合索引的英文证据 Recall@5 最强 (0.713)，但中文降至 0.560；双语索引取得最高均衡均值。在 27,668 条切分声明中，混合检索通常记录更高的自动语义支持，但高支持分数不能弥补引用

表 III: 补充信息系统验证结果

| 验证项目                 | 中文    | 英文    | 运行结果                     |
|----------------------|-------|-------|--------------------------|
| 双语字段混合索引，证据 Recall@5 | 0.718 | 0.675 | 最高均衡均值 (0.696)           |
| 原始 Qwen 混合，支持声明代理    | 0.878 | 0.836 | 引用精确率 0.955/0.970        |
| Qwen QLoRA 混合，支持声明代理 | 0.964 | 0.905 | 引用召回率 0.000/0.002        |
| 治理历史                 | -     | -     | 1,337 个事件；82 次编辑；两名记录审核者 |

缺失：Qwen QLoRA 保持较强支持分数，却几乎从不附加有效标签。治理数据库包含 37,664 条记录和 1,337 个审核事件，并保存编辑前状态快照；当前只有三条记录被拒绝，因此本实验不提供审批与拒绝之间的质量对比。审计中有两个不同审核者标识符，与第 3.2 节的报告边界一致。图 7 将索引字段、证据支持和治理审计分别置于 A-C 面板，而不是合并为单一分数。






图 7: 三项互补的信息系统验证。A 面板检验双语索引字段, B 面板测量自动证据支持, C 面板审计治理历史; 三个面板按验证层次重新分布, 不合并为单一数值。

## 5 讨论

### 5.1 研究问题回答

**RQ1 关注双语检索。**证据等价对比产生了语言特定的结果。在本评估中，密集检索的中文召回更高，而精确术语使 BM25 在英文中具有竞争力。混合融合在两种语言上达到最高证据 Recall@5；字段对比显示双语索引的均衡结果最强，尽管英文专用索引在英文单项上最佳。混合检索时延更高，而词法检索仍是可信的较低成本配置。这些结论适用于预先指定的等价规则，而不是被排除记录的确切检索 (Robertson and Zaragoza, 2009; Cormack et al., 2009)。

**RQ2 关注检索策略、可执行资格与答案行为。**对每个被评估生成器而言，RAG 的答案重叠都高于无检索，但检索排名和答案质量排名并不相同。适配与 RAG 条件也呈现出不同的答案重叠和引用格式模式。适配答案的自动语义支持仍然较高，而引用召回接近 0，因此与检索证据的相关性和可见归因应作为不同要求处理。这对那些报告微调或 RAG 汇总提升的铁路领域系统构成限定 (Li et al., 2024, 2025; Luo et al., 2025; Huang et al., 2026)。投入实际运行前仍需要引用感知目标、受约束的引用插入和人工验证的蕴含检查。

正式生成器矩阵确认，审批混合 RAG 在中英文中对所有评估生成器都提高了相对于无检索的 Answer F1，但提升幅度取决于模型和语言。

仅审批与未过滤混合条件相同，是因为冻结生产索引中每条符合资格的记录都已经获批。实现与审计验证了资格能够被执行和追踪，从而回答了 RQ2 的治理部分；但它们不能提供审批与未审核之间的质量对比。本文贡献是可执行的审核状态机制，而不是声称审批本身提高了 F1。

**RQ3 关注双语适配和翻译。**仅完成部分监督的 QLoRA 显著改善留出问答，尤其是 Qwen，但适配质量取决于任务。问答提升与 Qwen 不对称的翻译退化及 GLM 严重的句子翻译失败同时出现。这与领域受限微调可能过拟合任务形式或翻译方向的担忧相呼应 (Hu et al., 2024; Vieira et al., 2024)。实际含义是，问答、术语翻译、句子翻译和引用遵循都需要独立的验收阈值，不能用汇总双语分数证明可部署。

现有的检索、索引字段、适配和 RAG 对比为所报告的性能差异提供了组件层面的证据。例如，结果显示双语字段能够平衡两种查询语言，检索也能在不同生成器上提高答案重叠。但是，这些比较尚未隔离每一项提升的单一因果机制，多语言表示、词法匹配、训练适配和提示行为仍存在部分耦合。因此，在把提升归因于某个单独组件之前，还需要进一步开展受控消融和由专家评分的错误分析。

### 5.2 系统与部署启示

领域知识增强应作为信息系统工作流评估，而非单一模型处理。治理决定证据资格，检索决定证据可得性，生成决定证据使用，界面决定来源可见性。PostgreSQL 保存权威记录，pgvector 提供语义访问；原始 Qwen 资源占用较低，Qwen QLoRA 问答效果更强，但引用和翻译应设置独立门槛。结果支持分阶段本地部署，但不等同于教育成效验证。

## 6 实践启示与结论

本文展示了一种面向双语铁路教育与从业人员发展的受约束人工智能工作流。混合检索取得最强证据 Recall@5，双语字段取得最强均衡结果。Qwen2.5 QLoRA 取得最强留出问答和 RAG 答案重叠，但显存占用更高、生成更慢，引用遵循和翻译表现不稳定。系统应作为学习与决策支持，不应替代安全关键业务的现行规章；教师和运维人员应先检查系统显示的证据。

## 7 声明

数据可用性：合理请求下，数据可向通讯作者索取，但须符合权利和访问条件。

伦理与同意：未使用学习者个人数据。

利益冲突：无。

经费：无。

作者贡献：所有作者共同参与研究并批准稿件。

致谢：无。

生成式人工智能使用：人工智能仅用于润色英文语法。作者对稿件负责。

## 参考文献

- Barnett, S., Brannelly, Z., Kurniawan, S., and Wong, S. (2024). Fine-tuning or fine-failing? debunking performance myths in large language models. *arXiv preprint arXiv:2406.11201*. Available at: <https://arxiv.org/abs/2406.11201>.
- Chang, Y., Wang, X., Wang, J., Wu, Y., Yang, L., Zhu, K., Chen, H., Yi, X., Wang, C., Wang, Y., Ye, W., Zhang, Y., Chang, Y., Yu, P. S., Yang, Q., and Xie, X. (2024). A survey on evaluation of large language models. *ACM Transactions on Intelligent Systems and Technology*, 15(3):1–45. DOI: <https://doi.org/10.1145/3641289>.
- Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., and Liu, Z. (2024). Bge m3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *arXiv preprint arXiv:2402.03216*. Available at: <https://arxiv.org/abs/2402.03216>.
- Cormack, G. V., Clarke, C. L. A., and Buettcher, S. (2009). Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference*, pages 758–759. DOI: <https://doi.org/10.1145/1571941.1572114>.
- Dettmers, T., Pagnoni, A., Holtzman, A., and Zettlemoyer, L. (2023). Qlora: Efficient finetuning of quantized llms. In *Advances in Neural Information Processing Systems*, volume 36. Available at: <https://arxiv.org/abs/2305.14314>.
- Ding, N., Qin, Y., Yang, G., Wei, F., Yang, Z., Su, Y., Hu, S., Chen, Y., Chan, C.-M., and Chen, W. (2023). Parameter-efficient fine-tuning of large-scale pre-trained language models. *Nature Machine Intelligence*, 5(3):220–235. DOI: <https://doi.org/10.1038/s42256-023-00626-4>.
- GLM Team (2024). Chatglm: a family of large language models from glm-130b to glm-4 all tools. Available at: <https://arxiv.org/abs/2406.12793>.
- Hu, T., Zhang, P., Yang, B., Xie, J., Wong, D. F., and Wang, R. (2024). Large language model for multi-domain translation: benchmarking and domain cot fine-tuning. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 5726–5746. DOI: <https://doi.org/10.18653/v1/2024.findings-emnlp.328>.

- Huang, L., Liu, Z., Yu, C., Zhu, T., and Yan, B. (2026). Emergency operation scheme generation for urban rail transit train door systems using retrieval-augmented large language models. *Sensors*, 26(6):2006. DOI: <https://doi.org/10.3390/s26062006>.
- Hübscher, G., Geist, V., Auer, D., Hübscher, N., and Küng, J. (2021). Representation and presentation of knowledge and processes – an integrated approach for a dynamic communication-intensive environment. *International Journal of Web Information Systems*, 17(6):669–697. DOI: <https://doi.org/10.1108/IJWIS-03-2021-0031>.
- Kasneci, E., Sessler, K., Küchemann, S., Bannert, M., Dementieva, D., Fischer, F., Gasser, U., Groh, G., Günnemann, S., Hüllermeier, E., Krusche, S., Kutyniok, G., Michaeli, T., Nerdel, C., Pfeffer, J., Poquet, O., Sailer, M., Schmidt, A., Seidel, T., Stadler, M., Weller, J., Kuhn, J., and Kasneci, G. (2023). Chatgpt for good? on opportunities and challenges of large language models for education. *Learning and Individual Differences*, 103:102274. DOI: <https://doi.org/10.1016/j.lindif.2023.102274>.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-T., Rocktäschel, T., Riedel, S., and Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474. Available at: <https://arxiv.org/abs/2005.11401>.
- Li, J., Li, C., Niu, S., and Dai, B. (2024). Rschat: intelligent question answering model for railway safety knowledge. In *2024 IEEE/ACIS 24th International Conference on Computer and Information Science*, pages 55–60. DOI: <https://doi.org/10.1109/ICIS61260.2024.10778327>.
- Li, Y., Chen, J., Luo, X., and Zheng, H. (2025). Intelligent human-computer interactive training assistant system for rail systems. *High-speed Railway*, 3(1):64–77. DOI: <https://doi.org/10.1016/j.hspr.2025.02.001>.
- Luo, Y. C., Xun, J., Wang, W., Zhang, R. Z., and Zhao, Z. C. (2025). A driver advisory system based on large language model for high-speed train. Available at: <https://arxiv.org/abs/2501.07837>.
- Lv, K., Yang, Y., Liu, T., Guo, Q., and Qiu, X. (2024). Full parameter fine-tuning for large language models with limited resources. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*, pages 8187–8198. DOI: <https://doi.org/10.18653/v1/2024.acl-long.445>.
- Qwen Team (2024). Qwen2.5 technical report. Available at: <https://arxiv.org/abs/2412.15115>.
- Qwen Team (2025). Qwen3 technical report. Available at: <https://arxiv.org/abs/2505.09388>.
- Robertson, S. and Zaragoza, H. (2009). The probabilistic relevance framework: Bm25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389. DOI: <https://doi.org/10.1561/15000000019>.
- Schwartz, R., Dodge, J., Smith, N. A., and Etzioni, O. (2020). Green ai. *Communications of the ACM*, 63(12):54–63. DOI: <https://doi.org/10.1145/3381831>.

- Tian, K., Mitchell, E., Yao, H., Manning, C., and Finn, C. (2024). Fine-tuning language models for factuality. In *International Conference on Learning Representations*. Available at: [https://proceedings.iclr.cc/paper\\_files/paper/2024/hash/c361ae924c23cafca6033610d25dbc65-Abstract-Conference.html](https://proceedings.iclr.cc/paper_files/paper/2024/hash/c361ae924c23cafca6033610d25dbc65-Abstract-Conference.html).
- UNESCO (2023). Guidance for generative ai in education and research. Available at: <https://unesdoc.unesco.org/ark:/48223/pf0000386693>.
- Vieira, I., Allred, W., Lankford, S., Castilho, S., and Way, A. (2024). How much data is enough data? fine-tuning large language models for in-house translation. In *Proceedings of the 16th Conference of the Association for Machine Translation in the Americas*, pages 236–249. Available at: <https://aclanthology.org/2024.amta-research.20/>.
- Wang, L., Chen, S., Jiang, L., Pan, S., Cai, R., Yang, S., and Yang, F. (2025). Parameter-efficient fine-tuning in large language models: a survey of methodologies. *Artificial Intelligence Review*, 58(8):227. DOI: <https://doi.org/10.1007/s10462-025-11236-4>.
- Wooldridge, M. and Jennings, N. R. (1995). Intelligent agents: theory and practice. *The Knowledge Engineering Review*, 10(2):115–152. DOI: <https://doi.org/10.1017/S0269888900008122>.
- Xi, Z., Chen, W., Guo, X., He, W., Ding, Y., Hong, B., Zhang, M., Wang, J., Jin, S., Zhou, E., Zheng, R., Fan, X., Wang, X., Xiong, L., Zhou, Y., Wang, W., Jiang, C., Zou, Y., Liu, X., Yin, Z., Dou, S., Weng, R., Qin, W., Zheng, Y., Qiu, X., Huang, X., Zhang, Q., and Gui, T. (2025). The rise and potential of large language model based agents: a survey. *Science China Information Sciences*, 68(2):121101. DOI: <https://doi.org/10.1007/s11432-024-4222-0>.
- Yang, X., Wang, Z., Wang, Q., Wei, K., Zhang, K., and Shi, J. (2024). Large language models for automated q&a involving legal documents: a survey on algorithms, frameworks and applications. *International Journal of Web Information Systems*, 20(4):413–435. DOI: <https://doi.org/10.1108/IJWIS-12-2023-0256>.
- Zheng, J., Hong, H., Liu, F., Wang, X., Su, J., Liang, Y., and Wu, S. (2024). Fine-tuning large language models for domain-specific machine translation. Available at: <https://arxiv.org/abs/2402.15061>.