

资源约束下双语铁路职业教育的知识增强型大语言模型

摘要

研究背景：本研究评估一种受治理的知识增强型双语 workflow，考察其是否能够支持铁路职业问答，同时保持证据访问和审核状态的可追溯性。

研究方法：研究构建专家治理的双语语料，并按照知识对标识符将其划分为训练、验证和留出记录。实验比较 Qwen2.5-7B 和 GLM-4-9B 在仅完成部分监督的 QLoRA 适配前后的表现，并以 Qwen3-14B 作为参考模型；在留出双语查询上比较 BM25、BGE-M3 密集检索与倒数排名融合混合检索，随后开展受控的检索增强生成和资源检查。

研究结果：混合检索在中文和英文上的证据 Recall@5 分别达到 0.715 和 0.708；双语字段索引取得最高的跨语言均衡均值 0.696。Qwen QLoRA 将中文留出问答字符级 F1 从 0.189 提升至 0.398，将英文从 0.437 提升至 0.648。在审批混合检索增强生成条件下，所有受评估生成器和语言的 Answer F1 均有所改善，Qwen QLoRA 达到 0.660 和 0.651。翻译和引用遵循结果取决于具体任务。

研究结论：混合词法—密集检索在本评估条件下有效改善了双语证据访问，并提升了检索增强问答质量；双语字段索引也取得了最强的跨语言均衡结果。翻译和引用遵循结果取决于具体任务和语言。

关键词：双语铁路教育；检索增强生成；QLoRA 适配；Web 信息系统

1 引言

中国高铁的发展备受国际瞩目，也带来了双语技术交流和职业培训需求。然而，交流过程中存在语言、术语、来源获取和审核方式差异等问题。铁路职业教育涉及安全关键规章、专业术语和程序性教材知识，学习者和从业人员常需在中文源材料与英文学习支持之间切换。通用大语言模型虽能生成流畅答案，却难以清晰区分已验证知识与无依据生成。因此，系统必须在受控的本地 workflow 中完成双语知识的获取、治理、检索、呈现和溯源。

目标用户不仅包括学生，也包括铁路职工、教师、培训师、技术顾问和管理人员。系统不能只翻译术语，还应将双语问题连接到合规规章或教学段落，保留来源并显示审核状态。已有研究关注铁路安全、设计、轨道管理、预测性维护、司机建议和交互式培训，但双语访问、证据治理与可复现本地部署仍缺乏综合研究。

本文将有限资源定义为可复现的单工作站约束，具体硬件配置在方法部分说明。

现有研究通常分别评估通用语言模型或检索增强生成。本文重点处理三个评估缺口：双语检索很少按查询语言分别报告；审核状态常被当作预处理，而没有在检索阶段执行；领域适配也常只看目标任务，未同时检查翻译和引用遵循。此外，使用“智能体”一词的研究未必明确其动作边界，也较少把检索质量与本地运行成本联系起来。本文在同一受控比较中处理这些问题。

本文回答以下研究问题：

- **RQ1:** BM25、pgvector 密集检索和混合融合，对中英文留出铁路问答对的证据等价索引记录检索准确度如何？

- **RQ2:** 不同检索策略如何影响答案重叠和引用格式遵循？仅审批记录的资格限制能否在检索时被执行和审计？
- **RQ3:** 两个翻译方向分别达到怎样的双语翻译质量？在按知识对分组的留出评估下，仅完成部分监督的 QLoRA 如何影响领域问答？

本文评估一种由审核记录、词法—密集混合检索和证据条件化本地生成组成的双语铁路问答工作流。研究分别测量检索与证据访问、答案质量、引用行为、翻译和本地资源使用。混合检索在两种语言上取得最佳证据召回，并在生成器矩阵中改善检索增强答案质量；适配和翻译结果则取决于具体任务。

2 相关工作

2.1 知识增强型 Web 信息系统

Web 信息系统日益结合结构化数据管理、语义访问和生成式界面。《International Journal of Web Information Systems》中的研究表明，应整合知识表示、流程状态和面向用户的任务，而不是把它们视为彼此孤立的技术组件 (Hübscher et al., 2021)。检索增强生成 (RAG) 在参数化生成与外部维护的证据集合之间提供了实用分离 (Lewis et al., 2020)。这对机构知识系统很重要，因为源记录可以修订，而无需重新训练生成器。但这种分离并不保证生成忠实：检索可能遗漏相关证据，生成器也可能错误表述已正确检索的材料。因此，本文将检索、答案重叠、证据支持和引用格式行为作为不同结果分别评估。

检索层结合互补的词法和语义信号。BM25 仍是精确领域术语的高效词法基线 (Robertson and Zaragoza, 2009)，倒数排名融合则可以在不要求分数尺度直接可比的情况下合并排序 (Cormack et al., 2009)。PostgreSQL 和 pgvector 将向量检索置于受治理的关系元数据旁边，使审批状态和留出划分边界能够在查询中应用，而不是在生成后再处理。这使知识治理成为可执行的信息系统设计的一部分。

因此，本文把检索作为信息系统工作流的一部分，而不是孤立的文档 RAG 演示。记录身份和审核状态从摄取保留到呈现，嵌入则作为审核记录的派生字段保存。记录状态改变后，数据库层会同步改变其检索资格，无需重建应用。

2.2 教育领域的检索增强生成

生成式人工智能可以支持解释、反馈和学习资源访问，但教育研究也指出了事实可靠性、学习者过度依赖和来源不透明等风险 (Kasneci et al., 2023; UNESCO, 2023)。法律文档自动问答的综述证据同样表明，专业大语言模型服务需要协调数据处理、模型调整和应用框架，而不能只替换模型 (Yang et al., 2024)。教育 RAG 通过以课程或机构材料为条件，部分缓解了这一问题。然而，许多演示仍只报告汇总答案分数，没有分离检索失败、语言影响或部署成本。对于国际职业教育，这种汇总尤其不合适，因为英文问题可能需要从中文规章或教材中获取证据。因此，本文分别报告中文和英文的检索与生成结果，并在每个检索结果中保留文档级来源。

铁路应用提供了相关案例。RSChat 面向铁路安全问答 (Li et al., 2024)，已有大语言模型培训助手在铁路调度和职业培训中得到评估 (Li et al., 2025)；其他系统则面向列车司机建议和应急响应生成 (Luo et al., 2025; Huang et al., 2026)。本文进一步评估跨语言检索：英语问题可能需要调用中文规章或教材中的证据，同时在答案工作流中保留检索来源和审核状态。

2.3 受约束智能体与资源感知部署

经典智能体研究把智能体与情境化行动和一定程度的自主性联系起来 (Wooldridge and Jennings, 1995), 近期大语言模型智能体综述则把规划、记忆、工具使用和环境行动描述为常见但并非固定的组成部分 (Xi et al., 2025)。本文以更窄的操作性含义使用“**受约束工作流智能体**”一词。其固定动作空间包括: 路由中英文语言字段, 调用由用户或运维人员选择的 BM25、向量或混合检索器, 强制执行记录资格, 组装编号证据, 调用本地生成器, 并返回确定性的无证据或检索回退。它不设定开放式目标, 不浏览外部 Web, 不选择任意工具, 也不能在未经人工审批时修改知识库。检索模式与 $\text{top-}k$ 仍由用户或运维人员配置。该边界使本文服务区别于自主通用智能体, 并使每项动作可审计。

资源感知评估也是这一边界的一部分。高效人工智能研究主张, 计算成本与效率应和预测质量共同报告 (Schwartz et al., 2020)。对于本地智能体, 小型适配器文件或较低的可训练参数占比都不能证明推理内存或时延较低。因此, 本文把明确的工作站配置、峰值预留 GPU 内存、生成速度和时延作为可复现性条件, 而不依据参数数量推断可负担性。

2.4 双语领域适配与评估

双语领域系统既需要跨语言检索, 也需要受控生成。BGE-M3 支持多语言密集检索, 本文选用它为中文和英文知识字段提供共享嵌入空间 (Chen et al., 2024)。本文不预设密集相似度优于词法匹配, 而是在融合前分别比较两种方法。

参数高效适配是领域专门化的另一种机制。QLoRA 通过冻结的 4-bit 量化基础模型训练低秩适配器, 在保留任务适配能力的同时降低内存需求 (Dettmers et al., 2023)。本文使用仅完成部分的掩码, 使提示词不参与训练损失; 共享知识对标识符的双语变体被放入同一划分。翻译按方向评估, 因为中译英和英译中的分数不可直接互换; 术语翻译与完整句子翻译也分别保留。

PEFT 方法可以减少可训练参数, 但不保证部署后的系统更好 (Ding et al., 2023; Wang et al., 2025)。资源受限训练仍对量化、序列长度、优化器状态和模型特定目标模块敏感 (Lv et al., 2024)。此外, 任务适配可能提升答案重叠, 却损害事实性、指令遵循或无关能力 (Tian et al., 2024; Barnett et al., 2024)。因此, 本文采用前后对比设计, 除领域问答外, 还报告通用能力检查、引用行为和内存使用。

这些问题说明, 评估不能只看答案生成。本文同时报告模型质量、检索质量、引用行为、时延和峰值内存; 参数效率本身不被视为可部署性的证据 (Ding et al., 2023; Lv et al., 2024; Wang et al., 2025)。

领域翻译进一步带来汇总评估风险。既有工作表明, 微调效果取决于训练方向、领域组成和数据量 (Hu et al., 2024; Vieira et al., 2024; Zheng et al., 2024)。因此, 本文不把单一双语均值解释为稳健翻译的证据, 而是分别报告两个方向上的术语和句子任务, 并保留空输出或错误语言输出作为失败, 而不将它们静默删除。

3 系统设计与研究方法

3.1 应用场景与需求

目标用户分为四类角色。第一类为学习者, 包括国际学生、职业技能培训学员和需要双语支持的中文学习者; 第二类为铁路从业者, 包括跨境铁路环境中的铁路服务人员、当地在职职工和技术骨干; 第三类为教育与咨询人员, 包括职业院校教师、企业培训师和技术顾问; 第四类为管理与系统运维人员, 包括培训管理者和平台管理员。这四类角色对应三个访问群组:

学习者和铁路从业者使用双语门户；教师、培训师和技术顾问使用审核控制台；管理者和管理员使用运维控制台。系统必须返回简洁答案，展示编号证据，保留文档元数据，并在不要求云端推理的情况下运行于定义的工作站。

图 1 从左到右展示双语铁路问答 workflow。受治理的双语输入先映射到共享的 BGE-M3 表示空间，再经过密集检索和 BM25 检索、排名融合，并以编号证据的形式输入最右侧的证据条件化生成模块。最右侧模块包含冻结的解码器路径和并行的 QLoRA 低秩适配路径；适配器更新任务相关的低秩参数，而基础模型权重保持冻结。最终答案由独立的问答、引用、翻译、证据支持和资源使用指标进行评估。

图 1 最右侧模块将证据条件化推理与仅答案监督的适配过程区分开来。适配阶段按知识对标识符划分经过审核的双语问答对，屏蔽提示词 token，仅对答案 token 计算训练损失；推理阶段则将序列化上下文提供给解码器，并可通过 QLoRA 对选定模块施加低秩更新。检索上下文和下游评估分数不通过编码器或生成器反向传播，因此各项结果分别报告。

3.2 专家治理的知识库

知识记录包括中英文问题和答案、证据、原文、源文档、章节、页码、任务类型、质量标记、审核状态和修订历史。PostgreSQL 存储受治理记录，pgvector 存储 1,024 维 BGE-M3 嵌入。生产索引排除被分配到留出测试划分的确切记录。

知识来源包括铁路术语、运营与安全规章，以及职业教材或概念材料。摄取过程尽可能保留源文档、章节和页码字段。中英文问题和答案被存储在逻辑记录的不同字段中，确保语言变体不丢失来源身份。嵌入通过记录标识符和模型版本关联，可以在不改变已审核文本的情况下重建。标记为 `Rejected`、`Needs Revision` 或属于冻结 RAG 测试的记录，在排序前排除。这个数据库层面的决定防止确切测试记录通过 BM25 或向量检索泄漏，但不能证明所有其他记录中都不存在语义等价证据。因此，检索结果被定义为证据等价召回，而不是确切记录召回。

本文作者共同构建并检查知识库以及训练和评估数据集；其综合专长覆盖铁路职业教育、国际职业教育、环境与数据分析，以及软件和多模态语言模型工程。




图 1: 双语铁路问答 workflow。流程从左到右依次经过受治理的双语输入、共享编码、词法与密集检索、融合排序、证据条件化生成和评估；下方分支展示冻结基础模型上的仅答案监督 QLoRA 适配。

3.3 检索与答案生成

BM25 对中英文问答字段和证据建立索引。密集检索使用 BGE-M3 对查询进行嵌入, 并按向量相似度排列文本块。混合检索使用倒数排名融合合并关键词和密集排序。Approved-Only 条件将审核状态作为数据库层面的资格过滤器。检索模式与 top- k 由用户或运维人员配置, 而不是由大语言模型自主选择。检索到的证据被编号, 并与要求使用查询语言回答和引用证据标签的指令一起提供给本地生成器。

按照 Cormack 等人 (Cormack et al., 2009) 的定义, 候选文档 d 的倒数排名融合分数为:

$$\text{RRF}(d) = \sum_{r \in \{\text{BM25, vector}\}} \frac{1}{k_0 + \text{rank}_r(d)}. \quad (1)$$

若文档不在某一检索器的候选列表中, 则该检索器的贡献为零。每个检索器的候选池固定为 50, 传统排名常数为 $k_0 = 60$; 在改变最终 top- k 之前先应用公式。这个受控的 top- k 对比只改变提供给生成器的证据量, 不改变上游搜索池。密集排序使用 BGE-M3 查询嵌入和 pgvector 距离, 词法排序则保留缩写、设备名称和规章编号等精确技术语言。每个返回的证据对象都包含记录标识符、源文档、任务类型和检索分数。

密集检索的余弦相似度定义为:

$$s_{\text{dense}}(q, d) = \frac{\mathbf{e}_q^\top \mathbf{e}_d}{\|\mathbf{e}_q\|_2 \|\mathbf{e}_d\|_2}. \quad (2)$$

仅答案监督的适配损失只在答案位置计算。令答案 token 的掩码为 1、提示词 token 的掩码为 0, 则:

$$\mathcal{L}_{\text{answer}}(\theta_A) = -\frac{1}{\sum_t m_t} \sum_t m_t \log p_{\theta_0, \theta_A}(y_t | y_{<t}, x). \quad (3)$$

其中 θ_0 为冻结的 NF4 基础权重, θ_A 为可训练的 LoRA 参数。独立双语问答使用字符级重叠指标; 对预测答案 $\hat{y}$ 和参考答案 y , 定义为:

$$P = \frac{|\hat{y} \cap y|}{|\hat{y}|}, \quad R = \frac{|\hat{y} \cap y|}{|y|}, \quad F1 = \frac{2PR}{P + R}. \quad (4)$$

配套 Web 系统通过 Vite 客户端与 FastAPI 后端提供知识审核、检索、对话访问和来源证据展示，为本地维护的知识库与生成器提供应用界面。本文的实验比较聚焦检索、模型输出及资源使用，Web 界面本身不构成教育有效性评估。生成答案被描述为证据条件化输出，因为引用格式遵循和语义支持需要分开评估。

3.4 双语 QLoRA 适配

适配数据集只由已审批记录生成，并按知识对标识符、任务类型和源文档划分。同一知识项的中英文变体被分配到同一分区。当前冻结的 80/10/10 语料包含 12,178 个训练、1,524 个验证和 1,526 个测试样本，按语言均衡，所有分区之间不存在知识对标识符重叠。为 RAG 评估保留的 120 个规章项目被强制放入测试分区，且从未用于训练。损失只在答案 token 上计算，所有提示词标签都以 Minus 100 屏蔽。

Qwen2.5-7B-Instruct 和 GLM-4-9B-Chat-HF 构成适配矩阵，其架构和后训练谱系记录于官方技术报告 (Qwen Team, 2024; GLM Team, 2024)。二者均在目标 GPU 上以 NF4 量化和 PEFT 适配器加载。Qwen 暴露独立的 Gate Projection 和 Up Projection 模块，而 GLM 使用融合的 Gate-Up Projection，因此需要模型特定的目标列表。正式 Rank 64 配置训练了 161,480,704 个 Qwen 参数和 190,382,080 个 GLM 参数，分别占量化训练过程可见参数的 3.58% 和 3.45%。Qwen3-14B 仅作为未适配参考生成器保留，并对应 Qwen3 技术报告 (Qwen Team, 2025)。

两次运行均使用 LoRA Rank 64、Alpha 16、Dropout 0.05、Learning Rate 2e-4、Maximum Sequence Length 1,024 和一个 epoch。单设备 Batch Size 为 1，Gradient Accumulation Steps 为 16，Warm-Up Ratio 为 0.03。实验配置固定随机种子 42。生成使用贪心解码，Temperature 为 0、Top-P 为 1，并设置任务相关的输出上限。仅完成部分监督将每个提示词 token 设为 Minus 100，因此训练优化的是答案序列，而不是让模型复述指令。这个选择需要通过实验检验，并不预设会改善所有下游行为。

3.5 评估设计

检索条件包括 BM25、向量、混合和审批混合。指标包括证据等价 Recall@1/3/5、MRR 和平均时延。正式生成器矩阵固定使用无检索、BM25-RAG 和审批混合 RAG，使五个生成器接收相同的缓存上下文。自动指标包括 Answer F1、参考答案包含率、引用格式覆盖率、引用缺失率和端到端时延。引用指标只作为指令遵循指标，不作为证据蕴含或事实幻觉指标。翻译使用 SacreBLEU、chrF++ 和 COMET，分别报告中译英和英译中的术语与句子任务。分项指标使检索分数、答案分数或资源指标不会被误当作其他结果的替代指标 (Chang et al., 2024)。

当前 k 个候选中至少有一个满足冻结匹配规则时，证据等价 Recall@ k 为 1。匹配规则包括：记录标识符相同；归一化后的标准证据与候选证据在任一方向上存在包含关系；或者源文档相同且标准答案包含在候选证据中。由于确切 RAG 测试记录被排除在生产索引之外，观察到的命中通常来自后两项证据等价条件，而不是记录身份相同。MRR 是第一个此类匹配的倒数排名均值。独立双语问答评估在两种语言中均使用字符级 F1：答案归一化并去除空白后，按字符多重重叠计算精确率和召回率。配对问答检验使用同一指标。RAG 评估则对中文单字和小写拉丁字母/数字词元计算重叠 F1。两种 F1 分别在各自评估设置内报告，不作为可互换的绝对分数。独立问答的参考答案包含率为二值指标，表示归一化参考答案是否包含于预测中；RAG 保存的参考答案包含分数在空白归一化后的参考答案被预测包含时为 1，否则回

退为 RAG F1，预测或参考为空时为 0。因此，后者是连续包含分数，而非二值包含率。引用格式覆盖率只记录所要求的证据标签语法是否出现，其补集报告为引用缺失率。

所有核心对比使用配对样本。均值指标配有 2,000 次重采样 bootstrap 的 95% 置信区间。原始模型与 QLoRA 的对比使用双侧配对 Wilcoxon 检验、配对效应量 Cohen's d_z ，并在分析配置所记录的预先指定比较族上进行 Holm 校正。探索性错误类别单独报告，不作为验证性假设检验。效率测量使用 30 个中文短问题、30 个英文短问题和 30 个规章导向长上下文问题；每个模型条件先预热一次，再测量三次。

3.6 实现与可复现性

正式实现与实验环境见表 I。被评估路径不需要多 GPU 或云端推理资源，冻结清单记录模型版本、输入哈希和生成资产，以支持结果复现。

表 I: 正式实现与实验环境	
组件	正式设置
数据库	PostgreSQL 16.14; pgvector 0.8.4
嵌入	BAAI/bge-m3; 1,024 维
适配生成器	Qwen2.5-7B-Instruct; GLM-4-9B-Chat-HF
参考生成器	通过 Ollama 0.19.0 使用 Qwen3-14B
训练	NF4 QLoRA; rank 64; 一个 epoch; 种子 42
硬件边界	单块 RTX 3090 24 GB; 32 GB RAM; 无多 GPU 或必需云端推理
统计分析	2,000 次 bootstrap; 配对 Wilcoxon; Cohen's d_z ; Holm 校正
软件	Linux; Python 3.11.15; PyTorch 2.11.0; Transformers 5.12.1; PEFT 0.18.1; bitsandbytes 0.49.2; Ollama 0.19.0

代码将测试集构建、嵌入、检索评估、生成器评估、适配和报告导出分离，防止分析脚本静默改变生产索引或训练划分。正式 RAG 矩阵中的生成器复用缓存检索上下文，因此模型比较接收相同证据。清单在冻结时记录 Git 状态和每个输入的哈希，以支持结果重建和跨运行的一致比较。

默认情况下，生产嵌入加载仅使用本地文件，因此运行服务不依赖不可用的模型注册表。审核和问答视图通过 Vite 与 FastAPI 服务渲染。环境、模型版本、划分统计和资产哈希随对比结果记录。

4 结果

4.1 知识库组成

数据库包含 37,661 条已审批记录和 37,109 条完整双语记录。冻结正式 RAG 测试后，37,261 个已审批非测试知识块具有 BGE-M3 嵌入。QLoRA 测试分区包含来自四个源文档的 763 个知识对。正式跨来源 RAG 集从该分区中选取 400 个知识对和 800 个按语言划分的查询，其中包括 150 个规章、127 个术语和 123 个教材/概念知识对，覆盖 17 种任务类型。早期 120 对规章试验是该正式集合的子集，仍保留在可复现产物中，但不再作为额外样本报告于主要结果。

4.2 正式跨来源双语检索

表 II: 400 个知识对上的正式跨来源证据等价检索

检索	语言	证据 R@1	证据 R@3	证据 R@5	MRR	平均时延 (ms)
BM25	中文	0.520	0.595	0.620	0.560	69.5
向量	中文	0.518	0.653	0.690	0.588	134.4
审批混合	中文	0.570	0.675	0.715	0.628	217.6
BM25	英文	0.570	0.670	0.685	0.620	59.0
向量	英文	0.463	0.553	0.580	0.509	134.4
审批混合	英文	0.570	0.668	0.708	0.620	209.2

表 II 报告正式证据等价检索对比。BM25 对英文术语查询尤其具有竞争力，而密集检索在本评估中记录了更高的中文证据召回。在每个最终截断点都固定 RRF 候选池为 50 时，混合融合在两种语言上都取得最高证据 Recall@5，但时延约为 BM25 的三倍。在这一受控评估中，将最终截断点从 3 增加到 8，使混合证据召回率从中文 0.675、英文 0.668 分别升至 0.743 和 0.723，而平均检索时延基本不变（图 2）。仅审批与未过滤混合结果相同，因为冻结实验中所有符合资格的索引记录都满足审批条件。




图 2: 不同 top-k 设置下混合检索的证据等价质量与时延。左图为证据 Recall@k，右图为平均检索时延。

4.3 QLoRA 适配与留出问答

图 3 展示 Qwen 仅答案监督 QLoRA 的训练损失曲线及 epoch 末验证点。该曲线描述一个 epoch 内的优化过程，不能证明模型在延长或重复训练安排下已经收敛。没有进行扩展超参数搜索符合资源受限设计，但也限制了关于适配器设置全局最优的主张。

在 1,526 个样本的留出双语问答集上，Qwen QLoRA 将中文字符级 F1 从 0.189 (95% CI 0.175–0.204) 提高到 0.398 (0.376–0.422)，英文从 0.437 (0.419–0.455) 提高到 0.648 (0.632–0.664)。GLM 中文从 0.192 提升到 0.410，英文从 0.498 提升到 0.552。四项配对提升在 Holm 校正后仍显著（所有调整后 p 值均低于 0.01）；Qwen 中英文的 Cohen’s d_z 分别为 0.569 和 0.634，GLM 分别为 0.614 和 0.146。因此，在这一字符级指标下，Qwen 提供了最强的均衡适配问答结果，而 GLM 较小的英文效应说明不应合并两种语言。这些样本层面检验不能估计不同训练随机种子之间的变异。

有限的通用能力检查发现, Qwen C-Eval/MMLU 准确率从 0.788/0.739 变为 0.775/0.728, GLM 从 0.675/0.673 变为 0.683/0.679。这些小幅变化不能说明广泛的灾难性遗忘, 但受限协议只是回归检查, 并非全面通用基准。




图 3: Qwen2.5-7B 和 GLM-4-9B 的仅答案监督 QLoRA 优化过程。曲线表示日志记录的训练损失; 菱形表示每个模型的 epoch 末验证点。

4.4 多生成器 RAG 对比

Holm 校正后, 审批混合 RAG 在每个生成器和语言上都显著提高了相对于无检索的 Answer F1。表 III 汇总主要比较; 所有生成器条件的各语言调整后 p 值均低于 0.01。Qwen QLoRA 取得最高绝对混合 RAG F1, 而原始 Qwen 从增加检索中获得的增量最大。BM25 与混合检索的答案质量不存在统一排序, 因此提升取决于适配、检索策略和语言。

表 III: 多生成器 RAG 对比

生成器	无检索 (中/英)	F1	审批混合 (中/英)	F1	增量 (中/英)	Holm 校正后 p 值 (中/英)
原始 Qwen	0.262 / 0.306		0.402 / 0.440		+0.141 / +0.133	1.89e-39 / 2.28e-42
原始 GLM	0.230 / 0.269		0.297 / 0.318		+0.067 / +0.048	1.13e-22 / 9.56e-31
Qwen QLoRA	0.630 / 0.573		0.660 / 0.651		+0.030 / +0.078	1.34e-06 / 1.41e-11
GLM QLoRA	0.398 / 0.331		0.476 / 0.351		+0.077 / +0.020	3.16e-09 / 9.37e-03
Qwen3-14B	0.295 / 0.336		0.442 / 0.454		+0.147 / +0.118	6.66e-32 / 7.58e-29

可追溯性结果有所不同。原始 Qwen 的引用格式覆盖率在中英文中由 BM25 条件下的 0.543/0.638 变为混合条件下的 0.595/0.643; Qwen3 则由 0.715/0.900 变为 0.788/0.905。相比之下, Qwen QLoRA 在混合条件下仅为 0.000/0.003, GLM 也呈现相同但较弱的适配相关

模式。在测试条件下，QLoRA 的答案重叠更强，但对评估目标中使用的引用指令遵循更弱，因此适配模型的引用缺失率接近 1。这是指令遵循失败，而不是实测的事实幻觉率。在实际系统中，Qwen2.5 QLoRA 可作为主要答案质量模型，而在加入引用感知适配之前，原始 Qwen 或 Qwen3 仍是更安全的可追溯性控制。

4.5 双向翻译

翻译效果取决于方向和任务。Qwen 的 COMET 在中译英术语上从 0.501 变为 0.509，在英译中句子上从 0.610 变为 0.614；但中译英句子从 0.656 降至 0.599，英译中术语从 0.596 降至 0.485。词汇指标也显示出并非普遍提升：中译英术语 chrF++ 从 10.41 增至 16.69，而句子 chrF++ 从 47.43 降至 31.28。相反的变化说明结果不能概括为单一提升或退化。

GLM QLoRA 是明显的失败案例。其句子 COMET 在中译英中从 0.667 降至 0.348，在英译中从 0.742 降至 0.343；两个方向的 corpus BLEU 均为 0。自动检查在 2,634 个翻译样本中发现 2,168 个空输出（82.3%）。这一结果不支持“面向问答的仅完成部分适配一般能够改善翻译”的结论。因此，术语和句子翻译应与问答评估分开报告。

五种部署条件均完成 270 次测量，未出现执行失败或 OOM。显存实测值统一以 GiB (2^{30} 字节) 表示。原始 Qwen 和 GLM 的 PyTorch 峰值预留显存为 5.49 和 6.76 GiB，生成速度为 31.9 和 22.7 token/s；对应 QLoRA 版本为 16.11 和 19.49 GiB，速度为 17.5 和 11.9 token/s。原始模型的峰值实际分配显存分别为 5.35 和 6.48 GiB，对应 QLoRA 版本为 15.40 和 7.20 GiB。预留显存包括缓存分配器的预留空间，不应解释为存活张量占用量或适配器固有开销。通过 Ollama 使用的 Qwen3-14B 峰值 GPU 进程显存为 14.26 GiB，速度为 78.5 token/s；这一显存统计并非 PyTorch 预留显存，跨后端显存和时延比较仅为描述性比较。Qwen 和 GLM 适配器约占 627 和 746 MB。GLM QLoRA 平均时延较低（2.63 秒）是由异常短输出或空输出造成的，并不表示效率更高。所有配置都适合目标 24 GB 工作站；原始 Qwen 的资源成本最低，Qwen QLoRA 在限制内提供最强问答质量。

图 4 展示 Qwen2.5/GLM 原始与 QLoRA 四种条件下，独立问答的双语平均字符级 F1 与生成时延、峰值预留显存之间的关系。质量与资源测量来自各自的评估负载。该图是质量与资源的描述性比较，而不是适配器开销的受控因果估计；图中不包含通过 Ollama 运行的 Qwen3。




图 4: Qwen2.5/GLM 原始与 QLoRA 四种条件下，独立问答双语平均字符级 F1 与生成时延、峰值预留显存 (GiB) 的关系。左图为平均生成时延；右图为 PyTorch 预留显存。质量与资源在不同负载上测量。

4.6 资源使用

4.7 索引、证据支持与治理验证

表 IV: 补充信息系统验证结果

验证项目	中文	英文	运行结果
双语字段混合索引，证据 Recall@5	0.718	0.675	最高均衡均值 (0.696)
原始 Qwen 混合，支持声明代理	0.878	0.836	引用精确率 0.955/0.970
Qwen QLoRA 混合，支持声明代理	0.964	0.905	引用召回率 0.000/0.002
治理历史	—	—	1,337 个事件；82 次编辑；两名记录审核者

表 IV 和图 5 分别展示三个检查。A 面板比较仅源字段、语言专用字段和双语字段索引；双语字段取得最强均衡结果，但英语单项以语言专用字段更好。B 面板对比全部检索证据和明确引用证据上的语义支持，将证据访问与可见归因分开。C 面板记录审核事件和修改前状态快照，以追踪状态变化和编辑字段。“—”表示该指标不按语言分别统计。




图 5: 三个验证检查。A 面板比较仅源字段、语言专用字段和双语字段索引；B 面板比较检索证据与明确引用证据的语义支持；C 面板审计不可变审核事件和修改前状态快照。“—”表示该指标不按语言分别统计。

5 讨论

5.1 研究问题回答

RQ1 关注双语检索。证据等价对比产生了语言特定的结果。在本评估中，密集检索的中文召回更高，而精确术语使 BM25 在英文中具有竞争力。混合融合在两种语言上达到最高证据 Recall@5；字段对比显示双语索引的均衡结果最强，尽管英文专用索引在英文单项上最佳。混合检索时延更高，而词法检索仍是可信的较低成本配置。这些结论适用于预先指定的等价规则，而不是被排除记录的确切检索 (Robertson and Zaragoza, 2009; Cormack et al., 2009)。

RQ2 关注检索策略、可执行资格与答案行为。对每个被评估生成器而言，RAG 的答案重叠都高于无检索，但检索排名和答案质量排名并不相同。适配与 RAG 条件也呈现出不同的答案重叠和引用格式模式。适配答案的自动语义支持仍然较高，而引用召回接近 0，因此与检索证据的相关性和可见归因应作为不同要求处理。这一结果说明，微调或 RAG 的效果不宜压缩为单一汇总指标 (Li et al., 2024, 2025; Luo et al., 2025; Huang et al., 2026)。投入实际运行前仍需要引用感知目标、受约束的引用插入和蕴含检查。

正式生成器矩阵确认，审批混合 RAG 在中英文中对所有评估生成器都提高了相对于无检索的 Answer F1，但提升幅度取决于模型和语言。

RQ3 关注双语适配和翻译。仅完成部分监督的 QLoRA 显著改善留出问答，尤其是 Qwen，但适配质量取决于任务。问答提升与 Qwen 不对称的翻译退化及 GLM 严重的句子翻译失败同时出现。这与领域受限微调可能过拟合任务形式或翻译方向的担忧相呼应 (Hu et al., 2024; Vieira et al., 2024)。实际含义是，问答、术语翻译、句子翻译和引用遵循都需要独立的验收阈值，不能用汇总双语分数证明可部署。

检索、治理和适配对比显示了该工作流在哪些方面有效。混合词法—密集检索改善了双语证据访问和检索增强答案重叠，报告的 QLoRA 条件也改善了留出领域问答。翻译结果存在方向和任务差异，适配模型的引用格式覆盖率也较低；因此，结果应按任务和语言解释，不能压缩为单一汇总分数。

6 实践启示与结论

本文展示了一种面向双语铁路教育与从业人员发展的受治理工作流。混合检索在两种语言上取得最强证据 Recall@5，双语字段取得最强均衡结果；审批混合检索增强生成使所有受评估生成器和语言的 Answer F1 均有所改善，Qwen2.5 QLoRA 在所评估矩阵中取得最强留出问答和 RAG 答案重叠。翻译和引用行为并非在所有条件下都改善，因此应按任务和语言解释这些结果，而不能使用汇总分数替代分项分析。系统应作为学习与决策支持，不应替代安全关键业务的现行规章。

参考文献

- Barnett, S., Brannnelly, Z., Kurniawan, S., and Wong, S. (2024). Fine-tuning or fine-failing? debunking performance myths in large language models. *arXiv preprint arXiv:2406.11201*. Available at: <https://arxiv.org/abs/2406.11201>.
- Chang, Y., Wang, X., Wang, J., Wu, Y., Yang, L., Zhu, K., Chen, H., Yi, X., Wang, C., Wang, Y., Ye, W., Zhang, Y., Chang, Y., Yu, P. S., Yang, Q., and Xie, X. (2024). A survey on evaluation of large language models. *ACM Transactions on Intelligent Systems and Technology*, 15(3):1–45. DOI: <https://doi.org/10.1145/3641289>.

- Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., and Liu, Z. (2024). Bge m3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *arXiv preprint arXiv:2402.03216*. Available at: <https://arxiv.org/abs/2402.03216>.
- Cormack, G. V., Clarke, C. L. A., and Buettcher, S. (2009). Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference*, pages 758–759. DOI: <https://doi.org/10.1145/1571941.1572114>.
- Dettmers, T., Pagnoni, A., Holtzman, A., and Zettlemoyer, L. (2023). Qlora: Efficient finetuning of quantized llms. In *Advances in Neural Information Processing Systems*, volume 36. Available at: <https://arxiv.org/abs/2305.14314>.
- Ding, N., Qin, Y., Yang, G., Wei, F., Yang, Z., Su, Y., Hu, S., Chen, Y., Chan, C.-M., and Chen, W. (2023). Parameter-efficient fine-tuning of large-scale pre-trained language models. *Nature Machine Intelligence*, 5(3):220–235. DOI: <https://doi.org/10.1038/s42256-023-00626-4>.
- GLM Team (2024). Chatglm: a family of large language models from glm-130b to glm-4 all tools. Available at: <https://arxiv.org/abs/2406.12793>.
- Hu, T., Zhang, P., Yang, B., Xie, J., Wong, D. F., and Wang, R. (2024). Large language model for multi-domain translation: benchmarking and domain cot fine-tuning. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 5726–5746. DOI: <https://doi.org/10.18653/v1/2024.findings-emnlp.328>.
- Huang, L., Liu, Z., Yu, C., Zhu, T., and Yan, B. (2026). Emergency operation scheme generation for urban rail transit train door systems using retrieval-augmented large language models. *Sensors*, 26(6):2006. DOI: <https://doi.org/10.3390/s26062006>.
- Hübscher, G., Geist, V., Auer, D., Hübscher, N., and Küng, J. (2021). Representation and presentation of knowledge and processes – an integrated approach for a dynamic communication-intensive environment. *International Journal of Web Information Systems*, 17(6):669–697. DOI: <https://doi.org/10.1108/IJWIS-03-2021-0031>.
- Kasneci, E., Sessler, K., Küchemann, S., Bannert, M., Dementieva, D., Fischer, F., Gasser, U., Groh, G., Günemann, S., Hüllermeier, E., Krusche, S., Kutyniok, G., Michaeli, T., Nerdel, C., Pfeffer, J., Poquet, O., Sailer, M., Schmidt, A., Seidel, T., Stadler, M., Weller, J., Kuhn, J., and Kasneci, G. (2023). Chatgpt for good? on opportunities and challenges of large language models for education. *Learning and Individual Differences*, 103:102274. DOI: <https://doi.org/10.1016/j.lindif.2023.102274>.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-T., Rocktäschel, T., Riedel, S., and Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474. Available at: <https://arxiv.org/abs/2005.11401>.

- Li, J., Li, C., Niu, S., and Dai, B. (2024). Rschat: intelligent question answering model for railway safety knowledge. In *2024 IEEE/ACIS 24th International Conference on Computer and Information Science*, pages 55–60. DOI: <https://doi.org/10.1109/ICIS61260.2024.10778327>.
- Li, Y., Chen, J., Luo, X., and Zheng, H. (2025). Intelligent human-computer interactive training assistant system for rail systems. *High-speed Railway*, 3(1):64–77. DOI: <https://doi.org/10.1016/j.hspr.2025.02.001>.
- Luo, Y. C., Xun, J., Wang, W., Zhang, R. Z., and Zhao, Z. C. (2025). A driver advisory system based on large language model for high-speed train. Available at: <https://arxiv.org/abs/2501.07837>.
- Lv, K., Yang, Y., Liu, T., Guo, Q., and Qiu, X. (2024). Full parameter fine-tuning for large language models with limited resources. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*, pages 8187–8198. DOI: <https://doi.org/10.18653/v1/2024.acl-long.445>.
- Qwen Team (2024). Qwen2.5 technical report. Available at: <https://arxiv.org/abs/2412.15115>.
- Qwen Team (2025). Qwen3 technical report. Available at: <https://arxiv.org/abs/2505.09388>.
- Robertson, S. and Zaragoza, H. (2009). The probabilistic relevance framework: Bm25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389. DOI: <https://doi.org/10.1561/15000000019>.
- Schwartz, R., Dodge, J., Smith, N. A., and Etzioni, O. (2020). Green ai. *Communications of the ACM*, 63(12):54–63. DOI: <https://doi.org/10.1145/3381831>.
- Tian, K., Mitchell, E., Yao, H., Manning, C., and Finn, C. (2024). Fine-tuning language models for factuality. In *International Conference on Learning Representations*. Available at: https://proceedings.iclr.cc/paper_files/paper/2024/hash/c361ae924c23cafca6033610d25dbc65-Abstract-Conference.html.
- UNESCO (2023). Guidance for generative ai in education and research. Available at: <https://unesdoc.unesco.org/ark:/48223/pf0000386693>.
- Vieira, I., Allred, W., Lankford, S., Castilho, S., and Way, A. (2024). How much data is enough data? fine-tuning large language models for in-house translation. In *Proceedings of the 16th Conference of the Association for Machine Translation in the Americas*, pages 236–249. Available at: <https://aclanthology.org/2024.amta-research.20/>.
- Wang, L., Chen, S., Jiang, L., Pan, S., Cai, R., Yang, S., and Yang, F. (2025). Parameter-efficient fine-tuning in large language models: a survey of methodologies. *Artificial Intelligence Review*, 58(8):227. DOI: <https://doi.org/10.1007/s10462-025-11236-4>.
- Wooldridge, M. and Jennings, N. R. (1995). Intelligent agents: theory and practice. *The Knowledge Engineering Review*, 10(2):115–152. DOI: <https://doi.org/10.1017/S0269888900008122>.

- Xi, Z., Chen, W., Guo, X., He, W., Ding, Y., Hong, B., Zhang, M., Wang, J., Jin, S., Zhou, E., Zheng, R., Fan, X., Wang, X., Xiong, L., Zhou, Y., Wang, W., Jiang, C., Zou, Y., Liu, X., Yin, Z., Dou, S., Weng, R., Qin, W., Zheng, Y., Qiu, X., Huang, X., Zhang, Q., and Gui, T. (2025). The rise and potential of large language model based agents: a survey. *Science China Information Sciences*, 68(2):121101. DOI: <https://doi.org/10.1007/s11432-024-4222-0>.
- Yang, X., Wang, Z., Wang, Q., Wei, K., Zhang, K., and Shi, J. (2024). Large language models for automated q&a involving legal documents: a survey on algorithms, frameworks and applications. *International Journal of Web Information Systems*, 20(4):413–435. DOI: <https://doi.org/10.1108/IJWIS-12-2023-0256>.
- Zheng, J., Hong, H., Liu, F., Wang, X., Su, J., Liang, Y., and Wu, S. (2024). Fine-tuning large language models for domain-specific machine translation. Available at: <https://arxiv.org/abs/2402.15061>.