

资源约束下双语铁路职业教育大语言模型的知识增强领域适配

摘要

研究背景：铁路技术国际化扩大了双语职业教育需求，但铁路规章、专业术语和教学材料仍难以跨语言一致获取。多数职业院校和地方研究团队的计算资源有限，因此本文研究一种可在单工作站上完成适配与评价的知识增强型铁路垂直领域大语言模型，用于支持双语铁路知识问答与国际化知识交流。

研究方法：研究构建经审核的双语铁路语料，并按知识对标识符划分训练、验证和留出记录。BM25 词法检索与 BGE-M3 密集检索通过倒数排名融合，为 Qwen2.5-7B 和 GLM-4-9B 提供铁路证据。两种模型采用仅答案监督的 QLoRA 完成领域适配，并与原始模型及 Qwen3-14B 参考模型进行留出领域问答、检索增强生成和资源使用对比。

研究结果：混合检索在中文和英文上的证据 Recall@5 分别达到 0.715 和 0.708，双语字段索引取得最高的跨语言均衡均值 0.696。Qwen QLoRA 将中文留出问答字符级 F1 从 0.189 提升至 0.398，将英文从 0.437 提升至 0.648。加入审批混合证据后，所有受评估生成器在两种语言上的 Answer F1 均有所提高，Qwen QLoRA 达到 0.660 和 0.651。全部受评估模型条件均符合 24 GB GPU 边界。

研究结论：词法—密集证据融合与参数高效适配能够在现实的本地计算条件下共同专门化中等规模大语言模型。检索知识和模型适配带来的增益可以分别验证，为无需多 GPU 训练的铁路垂直领域大语言模型提供了实践依据。

关键词：铁路垂直领域大语言模型；双语职业教育；混合检索；检索增强生成；QLoRA；参数高效微调

1 引言

高速铁路建设、运营和技术合作的国际化扩大了双语职业教育需求 (Lawrence et al., 2019; Xu, 2018)。跨国家和语言环境工作的铁路人员与学习者，需要理解往往首先以中文发布的运营规章、安全程序、设备术语和教学材料。因此，问题并不只是翻译孤立术语，而是要把任一语言提出的问题连接到相关铁路知识，并生成有技术证据支撑的答案。

大语言模型为组织和交流这些知识提供了可能，但通用模型并未针对特定铁路语料中的术语、证据边界和程序细节进行训练。流畅的回答还可能掩盖内容究竟来自适用规章还是参数化生成。既有研究已探索铁路安全、设计、轨道管理、预测性维护、司机建议和交互式培训中的专用模型 (Zheng et al., 2023; Lahnalampi, 2024; Wang and Li, 2024; Song et al., 2025; Luo et al., 2025; Li et al., 2025)，相关综述仍将可靠性和部署列为开放问题 (Wandelt et al., 2024)。因此，铁路领域模型既需要访问外部证据，也需要适配目标知识库的语言和回答方式。

计算条件构成第二项约束。许多职业院校和地方研究团队无法维持多 GPU 训练集群，也难以持续依赖商业云端推理。全参数适配大型模型因而难以复现且维护成本较高。量化低秩适配提供了更现实的路径：在基础权重冻结时，7B 或 9B 模型可使用单块 24 GB GPU 完成领域专门化。因此，资源限制是本文方法设计和实验评价的基本条件，而非次要部署细节。

本文通过两种互补机制构建并评价知识增强型铁路领域大语言模型。第一，融合 BM25 与 BGE-M3 排名，提高双语铁路证据获取能力；第二，使用仅答案监督的 QLoRA，在单工作站资源边界内适配 Qwen2.5-7B 和 GLM-4-9B 的铁路领域问答能力。受控对比分别测量检索效果、适配增益、检索增强答案质量和计算成本，以检验检索知识与参数高效适配能否共同强化垂直领域模型。

2 相关工作

2.1 知识增强型大语言模型

知识增强型大语言模型把参数化生成与外部维护的证据集合结合起来 (Lewis et al., 2020)。这种方式适合铁路教育，因为规章和教学记录可以修订，而无需重新训练模型的全部参数，同时还能建立答案与来源之间的明确联系。检索质量与生成质量仍是两个不同问题：检索器可能遗漏相关段落，生成器也可能未能利用已经正确检索的证据。因此，本文分别测量证据获取和答案质量。

知识表示和过程状态仍有必要，因为证据记录必须保留来源与资格元数据 (Hübscher et al., 2021)。本文以这些控制决定哪些铁路记录可以进入检索，并防止确切留出记录被返回。它们服务于领域模型评价，但不是本文的主要研究对象。

2.2 铁路教育的混合检索

生成式人工智能可以支持解释、反馈和学习资源访问，但教育研究也指出了事实可靠性、学习者过度依赖和来源不透明等风险 (Kasneci et al., 2023; UNESCO, 2023)。教育 RAG 通过使答案以课程或机构材料为条件，部分缓解这一问题。在双语铁路教育中，精确术语和规章编号有利于词法匹配，而不同表述的中英文问题则受益于语义检索。因此，BM25 与 BGE-M3 提供互补的证据排名，倒数排名融合可在不要求两种分数同尺度的条件下合并结果 (Robertson and Zaragoza, 2009; Cormack et al., 2009; Chen et al., 2024)。

铁路应用提供了相关案例。RSChat 面向铁路安全问答 (Li et al., 2024)，已有大语言模型培训助手在铁路调度和职业培训中得到评估 (Li et al., 2025)；其他系统则面向列车司机建议和应急响应生成 (Luo et al., 2025; Huang et al., 2026)。本文进一步开展受控跨语言检索比较，并检验检索证据如何改变原始模型、适配模型和较大参考模型的答案。

2.3 参数高效的铁路领域适配

参数高效适配是领域专门化的第二种机制。QLoRA 通过冻结的 4-bit 量化基础模型训练低秩适配器，在保留任务适配能力的同时降低训练内存 (Dettmers et al., 2023)。仅答案监督使目标集中于铁路答案，共享知识对标识符的中英文变体被放入同一划分，从而防止紧密相关的双语记录跨越训练与留出边界。

PEFT 方法可以减少可训练参数，但不保证得到更好的领域模型 (Ding et al., 2023; Wang et al., 2025)。资源受限训练仍对量化、序列长度、优化器状态和模型特定目标模块敏感 (Lv et al., 2024)。任务适配还可能提升目标任务重叠，同时改变指令遵循行为 (Tian et al., 2024; Barnett et al., 2024)。因此，需要通过适配前后对比分离领域问答增益与检索证据带来的影响。

高效人工智能研究还主张预测质量应与计算成本共同报告 (Schwartz et al., 2020)。适配器大小本身不能证明推理显存或时延较低。因此，实验在同一单工作站边界内报告留出铁路问答、检索增强答案质量、峰值 GPU 内存和生成速度。

3 知识增强型领域大语言模型方法

3.1 问题设定与模型概览

目标任务是根据经审核的铁路规章、术语记录和职业教学材料完成双语铁路问答。给定中文或英文问题，模型需要检索相关铁路证据，并以提问语言生成答案。资源边界为单块 RTX 3090 24 GB GPU 和 32 GB 系统内存，不使用多 GPU 训练，也不要求云端推理。该设定决定了中等规模基础模型、NF4 量化和 QLoRA 的选择。

图 1 概括构建铁路领域大语言模型的两种机制。证据路径使输入问题分别经过 BM25 和 BGE-M3，再通过倒数排名融合合并排序，将选出的铁路段落加入模型提示词。适配路径使用训练分区对冻结基础模型进行仅答案监督的 QLoRA。两条路径汇入同一证据条件化生成器，使检索增益与适配增益能够在统一留出协议下比较。

图中还明确了资源约束：只训练低秩适配器，基础模型和 BGE-M3 编码器均保持冻结。这样可以把有限计算集中于铁路回答方式的适配，同时允许证据集合在模型参数之外更新。图 1 所呈现的核心优势是两种专门化的互补性：混合检索补充铁路知识，QLoRA 改变模型回答铁路问题的能力。

3.2 双语铁路知识语料

知识记录包括中英文问题和答案、证据、原文、源文档、章节、页码、任务类型、质量标记、审核状态和修订历史。PostgreSQL 存储受治理记录，pgvector 存储 1,024 维 BGE-M3 嵌入。生产索引排除被分配到留出测试划分的确切记录。

知识来源包括铁路术语、运营与安全规章，以及职业教材或概念材料。摄取过程尽可能保留源文档、章节和页码字段。中英文问题和答案被存储在同一逻辑记录的不同字段中，确保语言变体不丢失来源身份。嵌入通过记录标识符和模型版本关联，可以在不改变已审核文本的情况下重建。标记为 `Rejected`、`Needs Revision` 或属于冻结 RAG 测试的记录，在排序前排除。这个数据库层面的决定防止确切测试记录通过 BM25 或向量检索泄漏，但不能证明所有其他记录中都不存在语义等价证据。因此，检索结果被定义为证据等价召回，而不是确切记录召回。




图 1: 铁路领域大语言模型的知识增强适配。证据路径通过倒数排名融合组合 BM25 词法排序与 BGE-M3 密集排序, 再将排名靠前的铁路段落加入提示词; 适配路径在基础模型保持冻结时训练仅答案监督的 QLoRA 参数。两条路径分别和联合评价, 以区分检索增益、领域适配增益及其资源成本。

3.3 混合检索与证据条件化生成

BM25 对中英文问答字段和证据建立索引, 保留铁路术语、设备名称和规章编号的精确匹配。密集检索使用 BGE-M3 对查询编码, 并按语义相似度排序知识块。倒数排名融合合并两种排序, 审批条件在排序前排除不合格或留出记录。排名靠前的段落被编号后加入模型提示词, 使生成器能够使用提问语言回答并输出证据标签。

按照 Cormack 等人 (Cormack et al., 2009) 的定义, 候选文档 d 的倒数排名融合分数为:

$$RRF(d) = \sum_{r \in \{\text{BM25}, \text{vector}\}} \frac{1}{k_0 + \text{rank}_r(d)}. \quad (1)$$

若文档不在某一检索器的候选列表中, 则该检索器的贡献为零。每个检索器的候选池固定为 50, 传统排名常数为 $k_0 = 60$; 在改变最终 top- k 之前先应用公式。这个受控的 top- k 对比只改变提供给生成器的证据量, 不改变上游搜索池。密集排序使用 BGE-M3 查询嵌入和 pgvector 距离, 词法排序则保留缩写、设备名称和规章编号等精确技术语言。每个返回的证据对象都包含记录标识符、源文档、任务类型和检索分数。

密集检索的余弦相似度定义为:

$$s_{\text{dense}}(q, d) = \frac{\mathbf{e}_q^\top \mathbf{e}_d}{\|\mathbf{e}_q\|_2 \|\mathbf{e}_d\|_2}. \quad (2)$$

仅答案监督的适配损失只在答案位置计算。令答案 token 的掩码为 1、提示词 token 的掩码为 0, 则:

$$\mathcal{L}_{\text{answer}}(\theta_A) = - \sum_t \frac{1}{m_t} \sum_t m_t \log p_{\theta_0, \theta_A}(y_t | y_{<t}, x). \quad (3)$$

其中 θ_0 为冻结的 NF4 基础权重, θ_A 为可训练的 LoRA 参数。独立双语问答使用字符级重叠指标; 对预测答案 $\hat{y}$ 和参考答案 y , 定义为:

$$P = \frac{|\hat{y} \cap y|}{|\hat{y}|}, \quad R = \frac{|\hat{y} \cap y|}{|y|}, \quad F1 = \frac{2PR}{P + R}. \quad (4)$$

训练后的模型和检索器通过本地 Vite 与 FastAPI 界面进行测试，但界面设计不属于实验比较。本文报告证据检索、模型输出和资源使用。检索段落进入提示词，因此输出被称为证据条件化答案；引用格式遵循与语义支持仍分别评价。

3.4 资源受限的 QLoRA 领域适配

适配数据集只由已审批记录生成，并按知识对标识符、任务类型和源文档划分。同一知识项的中英文变体被分配到同一分区。当前冻结的 80/10/10 语料包含 12,178 个训练、1,524 个验证和 1,526 个测试样本，按语言均衡，所有分区之间不存在知识对标识符重叠。为 RAG 评估保留的 120 个规章项目被强制放入测试分区，且从未用于训练。损失只在答案 token 上计算，所有提示词标签都以 Minus 100 屏蔽。

Qwen2.5-7B-Instruct 和 GLM-4-9B-Chat-HF 构成适配矩阵，其架构和后训练谱系记录于官方技术报告 (Qwen Team, 2024; GLM Team, 2024)。二者均在目标 GPU 上以 NF4 量化和 PEFT 适配器加载。Qwen 暴露独立的 Gate Projection 和 Up Projection 模块，而 GLM 使用融合的 Gate-Up Projection，因此需要模型特定的目标列表。正式 Rank 64 配置训练了 161,480,704 个 Qwen 参数和 190,382,080 个 GLM 参数，分别占量化训练过程可见参数的 3.58% 和 3.45%。Qwen3-14B 仅作为未适配参考生成器保留，并对应 Qwen3 技术报告 (Qwen Team, 2025)。

两次运行均使用 LoRA Rank 64、Alpha 16、Dropout 0.05、Learning Rate 2e-4、Maximum Sequence Length 1,024 和一个 epoch。单设备 Batch Size 为 1，Gradient Accumulation Steps 为 16，Warm-Up Ratio 为 0.03。实验配置固定随机种子 42。生成使用贪心解码，Temperature 为 0、Top-P 为 1，并设置任务相关的输出上限。仅答案监督将每个提示词 token 设为 Minus 100，因此训练优化铁路答案序列，而不是复述指令。

3.5 评估设计

检索条件包括 BM25、向量、混合和审批混合。指标包括证据等价 Recall@1/3/5、MRR 和平均时延。正式生成器矩阵固定使用无检索、BM25-RAG 和审批混合 RAG，使五个生成器接收相同的缓存上下文。自动指标包括 Answer F1、参考答案包含率、引用格式覆盖率、引用缺失率和端到端时延。引用指标只作为指令遵循指标，不作为证据蕴含或事实幻觉指标。方向性翻译仅作为辅助诊断，不用于定义模型的主要改进。分项指标使检索分数、答案分数或资源指标不会被误当作其他结果的替代指标 (Chang et al., 2024)。

当前 k 个候选中至少有一个满足冻结匹配规则时，证据等价 Recall@ k 为 1。匹配规则包括：记录标识符相同；归一化后的标准证据与候选证据在任一方向上存在包含关系；或者源文档相同且标准答案包含在候选证据中。由于确切 RAG 测试记录被排除在生产索引之外，观察到的命中通常来自后两项证据等价条件，而不是记录身份相同。MRR 是第一个此类匹配的倒数排名均值。独立双语问答评估在两种语言中均使用字符级 F1：答案归一化并去除空白后，按字符多重集重叠计算精确率和召回率。配对问答检验使用同一指标。RAG 评估则对中文单字和小写拉丁字母/数字词元计算重叠 F1。两种 F1 分别在各自评估设置内报告，不作为可互换的绝对分数。独立问答的参考答案包含率为二值指标，表示归一化参考答案是否包含于预测中；RAG 保存的参考答案包含分数在空白归一化后的参考答案被预测包含时为 1，否则回退为 RAG F1，预测或参考为空时为 0。因此，后者是连续包含分数，而非二值包含率。引用格式覆盖率只记录所要求的证据标签语法是否出现，其补集报告为引用缺失率。

所有核心对比使用配对样本。均值指标配有 2,000 次重采样 bootstrap 的 95% 置信区间。原始模型与 QLoRA 的对比使用双侧配对 Wilcoxon 检验、配对效应量 Cohen's d_z ，并在分析配置所记录的预先指定比较族上进行 Holm 校正。探索性错误类别单独报告，不作为验证性

假设检验。效率测量使用 30 个中文短问题、30 个英文短问题和 30 个规章导向长上下文问题；每个模型条件先预热一次，再测量三次。

3.6 资源受限实现

表 I 定义所有实验采用的单工作站边界。适配后的 7B 和 9B 模型既不需要多 GPU 训练，也不需要云端推理，使小型机构实验室可以在可获得的硬件上完成检索、适配和生成测试。

表 I: 单工作站实现与实验配置

组件	正式设置
数据库	PostgreSQL 16.14; pgvector 0.8.4
嵌入	BAAI/bge-m3; 1,024 维
适配生成器	Qwen2.5-7B-Instruct; GLM-4-9B-Chat-HF
参考生成器	通过 Ollama 0.19.0 使用 Qwen3-14B
训练	NF4 QLoRA; rank 64; 一个 epoch; 种子 42
硬件边界	单块 RTX 3090 24 GB; 32 GB RAM; 无多 GPU 或必需云端推理
统计分析	2,000 次 bootstrap; 配对 Wilcoxon; Cohen's d_z ; Holm 校正
软件	Linux; Python 3.11.15; PyTorch 2.11.0; Transformers 5.12.1; PEFT 0.18.1; bitsandbytes 0.49.2; Ollama 0.19.0

代码将测试集构建、嵌入、检索评估、生成器评估、适配和报告导出分离，防止分析脚本静默改变生产索引或训练划分。正式 RAG 矩阵中的生成器复用缓存检索上下文，因此模型比较接收相同证据。清单在冻结时记录 Git 状态和每个输入的哈希，以支持结果重建和跨运行的一致比较。

默认情况下，生产嵌入加载仅使用本地文件，因此运行服务不依赖不可用的模型注册表。审核和问答视图通过 Vite 与 FastAPI 服务渲染。环境、模型版本、划分统计和资产哈希随对比结果记录。

4 结果

4.1 知识库组成

数据库包含 37,661 条已审批记录和 37,109 条完整双语记录。冻结正式 RAG 测试后，37,261 个已审批非测试知识块具有 BGE-M3 嵌入。QLoRA 测试分区包含来自四个源文档的 763 个知识对。正式跨来源 RAG 集从该分区中选取 400 个知识对和 800 个按语言划分的查询，其中包括 150 个规章、127 个术语和 123 个教材/概念知识对，覆盖 17 种任务类型。早期 120 对规章试验是该正式集合的子集，仍保留在可复现产物中，但不再作为额外样本报告于主要结果。

4.2 正式跨来源双语检索

表 II 报告正式证据等价检索对比。BM25 对英文术语查询尤其具有竞争力，而密集检索在本评估中获得更高的中文证据召回。混合融合结合两者优势，在中文和英文上分别取得最高的 Evidence Recall@5，即 0.715 和 0.708。其平均时延约为 BM25 的三倍，因此该结果体

表 II: 400 个知识对上的正式跨来源证据等价检索

检索	语言	证据 R@1	证据 R@3	证据 R@5	MRR	平均时延 (ms)
BM25	中文	0.520	0.595	0.620	0.560	69.5
向量	中文	0.518	0.653	0.690	0.588	134.4
审批混合	中文	0.570	0.675	0.715	0.628	217.6
BM25	英文	0.570	0.670	0.685	0.620	59.0
向量	英文	0.463	0.553	0.580	0.509	134.4
审批混合	英文	0.570	0.668	0.708	0.620	209.2

现的是质量一时延权衡，而不是普遍的效率优势。仅审批与未过滤混合结果相同，因为冻结实验中所有符合资格的索引记录都满足审批条件。




图 2: 最终证据截断点对混合检索的影响。top-1 到 top-8 使中文/英文召回率由 0.570 提升至 0.743/0.723，而平均检索时延保持在约 218/209 ms，因为上游候选池固定。该图表明，在本实验中返回更多融合候选可以增加证据覆盖率，而不会显著改变检索时间。

图 2 显示，最终截断点从 1 增加到 8 时，两种语言的召回率持续提高，其中 top-1 到 top-3 的增幅最大，之后增益逐渐减小。时延曲线基本平坦，这是因为各设置复用相同的 BM25 与密集检索 50 条候选池。其客观优势是在不增加上游检索工作的情况下提高证据覆盖率，但向生成器提供更多段落仍可能增加上下文成本。

4.3 QLoRA 适配与留出问答

图 3 展示仅答案监督 QLoRA 的训练过程。两种模型的损失均在训练初期快速下降，随后缓慢降低，epoch 末验证损失位于最终训练损失附近。Qwen 的训练和验证损失最终均低于 GLM，这与其更强的留出双语问答结果一致。该图支持资源限制下单 epoch 优化有效，但不能证明更长训练或不同随机种子下已经收敛。

在 1,526 个样本的留出双语问答集上，Qwen QLoRA 将中文字符级 F1 从 0.189 (95% CI 0.175–0.204) 提高到 0.398 (0.376–0.422)，英文从 0.437 (0.419–0.455) 提高到 0.648 (0.632–0.664)。GLM 中文从 0.192 提升到 0.410，英文从 0.498 提升到 0.552。四项配对提升在 Holm 校正后仍显著（所有调整后 p 值均低于 0.01）；Qwen 中英文的 Cohen’s d_z 分别为 0.569 和 0.634，GLM 分别为 0.614 和 0.146。因此，在这一字符级指标下，Qwen 提供了最强的均衡适配问答结果，而 GLM 较小的英文效应说明不应合并两种语言。这些样本层面检验不能估计不同训练随机种子之间的变异。




图 3: 单 epoch 的仅答案监督 QLoRA 优化。两种模型的训练损失均快速下降后趋于稳定, epoch 末验证菱形位于最终训练损失附近。Qwen 的两项损失均低于 GLM, 为其更强的留出问答得分提供了相一致的优化证据。

4.4 多生成器 RAG 对比

Holm 校正后, 审批混合 RAG 在每个生成器和语言上都显著提高了相对于无检索的 Answer F1。表 III 汇总主要比较; 所有生成器条件的各语言调整后 p 值均低于 0.01。Qwen QLoRA 取得最高绝对混合 RAG F1, 而原始 Qwen 从增加检索中获得的增量最大。BM25 与混合检索的答案质量不存在统一排序, 因此提升取决于适配、检索策略和语言。

表 III: 多生成器 RAG 对比

生成器	无 检索 (中/英)	F1	审批混合 (中/英)	F1	增量 (中/英)	Holm 校正后 p 值 (中/英)
原始 Qwen	0.262 / 0.306	0.402 / 0.440			+0.141 / +0.133	1.89e-39 / 2.28e-42
原始 GLM	0.230 / 0.269	0.297 / 0.318			+0.067 / +0.048	1.13e-22 / 9.56e-31
Qwen QLoRA	0.630 / 0.573	0.660 / 0.651			+0.030 / +0.078	1.34e-06 / 1.41e-11
GLM QLoRA	0.398 / 0.331	0.476 / 0.351			+0.077 / +0.020	3.16e-09 / 9.37e-03
Qwen3-14B	0.295 / 0.336	0.442 / 0.454			+0.147 / +0.118	6.66e-32 / 7.58e-29

可追溯性结果有所不同。原始 Qwen 的引用格式覆盖率在中英文中由 BM25 条件下的 0.543/0.638 变为混合条件下的 0.595/0.643; Qwen3 则由 0.715/0.900 变为 0.788/0.905。相比之下, Qwen QLoRA 在混合条件下仅为 0.000/0.003, GLM 也呈现相同但较弱的适配相关模式。在测试条件下, QLoRA 的答案重叠更强, 但对评估目标中使用的引用指令遵循更弱, 因此适配模型的引用缺失率接近 1。这是指令遵循失败, 而不是实测的事实幻觉率。对于铁路领域问答, Qwen2.5 QLoRA 提供最强的答案重叠; 在加入引用感知适配之前, 原始 Qwen 和 Qwen3 的引用格式遵循更强。

4.5 辅助翻译检查

辅助翻译检查显示，适配后的变化取决于翻译方向和任务类型。由于本文主要研究铁路领域问答，翻译结果仅作为诊断保留，不用于定义模型的主要改进。

4.6 资源使用

资源测量用于检验领域适配模型能否在设定的单工作站上运行，并量化问答质量提升所对应的计算成本。

五种部署条件均完成 270 次测量，未出现执行失败或 OOM。显存实测值统一以 GiB (2^{30} 字节) 表示。原始 Qwen 和 GLM 的 PyTorch 峰值预留显存为 5.49 和 6.76 GiB，生成速度为 31.9 和 22.7 token/s；对应 QLoRA 版本为 16.11 和 19.49 GiB，速度为 17.5 和 11.9 token/s。原始模型的峰值实际分配显存分别为 5.35 和 6.48 GiB，对应 QLoRA 版本为 15.40 和 7.20 GiB。预留显存包括缓存分配器的预留空间，不应解释为存活张量占用或适配器固有开销。通过 Ollama 使用的 Qwen3-14B 峰值 GPU 进程显存为 14.26 GiB，速度为 78.5 token/s；这一显存统计并非 PyTorch 预留显存，跨后端显存和时延比较仅为描述性比较。Qwen 和 GLM 适配器约占 627 和 746 MB。GLM QLoRA 平均时延较低（2.63 秒）是由异常短输出或空输出造成的，并不表示效率更高。所有配置都适合目标 24 GB 工作站；原始 Qwen 的资源成本最低，Qwen QLoRA 在限制内提供最强问答质量。

图 4 将双语独立问答平均 F1 与生成时延、峰值预留显存联系起来。Qwen QLoRA 在两个面板中均位于最高质量位置，且仍低于 24 GB 边界，说明目标工作站能够实现最强的适配问答结果。原始模型使用的显存明显更少，因此质量提升伴随可测量的资源成本。该图是描述性比较，不是适配器开销的受控因果估计；通过 Ollama 运行且显存统计口径不同的 Qwen3 未纳入图中。




图 4: 原始模型与 QLoRA 适配模型的质量—资源比较。Qwen QLoRA 取得最高双语问答平均 F1，且保持在 24 GB GPU 边界内；其更高时延和预留显存体现了该增益的成本。GLM QLoRA 的低时延来自异常短输出或空输出，不解释为效率优势。

4.7 辅助证据与语料控制检查

图 5 检查领域模型背后的知识组件是否按预期工作，包括语言字段选择、生成声明能否由检索证据或明确引用证据支持，以及语料审核操作是否被记录。这些检查用于补充主要检索与问答结果。




图 5: 知识增强模型的辅助验证。A 面板表明双语索引提供最强的跨语言 Recall@5 均衡性；B 面板显示全部检索证据具有较高语义支持，但明确引用证据的支持明显较低，尤其是在 QLoRA 后；C 面板确认语料审批和编辑操作均被记录。三个面板分别说明证据访问、可见归因和数据控制。

表 IV: 辅助证据访问、归因和语料控制结果

验证项目	中文	英文	运行结果
双语字段混合索引, 证据 Recall@5	0.718	0.675	最高均衡均值 (0.696)
原始 Qwen 混合, 支持声明代理	0.878	0.836	引用精确率 0.955/0.970
Qwen QLoRA 混合, 支持声明代理	0.964	0.905	引用召回率 0.000/0.002
治理历史	—	—	1,337 个事件；82 次编辑；两名记录审核者

图 5 的 A 面板说明保留双语索引的原因：中文与英文 Recall@5 分别为 0.718 和 0.675，形成最高的均衡均值 0.696，尽管英文专用字段在英文单项上更高。B 面板显示，生成声明通常能在全部检索上下文中获得较高语义支持，其中 Qwen QLoRA 为 0.964/0.905；但明确引用证据上的支持明显较低，说明证据已被检索并不等同于模型输出了可见引用。C 面板记录 1,337 次语料操作及编辑字段，表明训练和检索证据具有可检查的变更历史。该图因此既展示双语证据访问的优势，也把剩余弱项定位为引用行为，而非检索证据本身不足。

5 讨论

5.1 混合证据检索的有效性

检索实验表明，词法信号与密集语义信号解决了铁路证据获取中的不同问题。BM25 对精确英文术语和规章标识保持较强表现，BGE-M3 则能检索语义相关性更强的中文证据。倒数排名融合保留两类排序中的有效候选，并在中英文中取得最高 Evidence Recall@5。字段消融进一步表明，双语字段索引取得最强的跨语言均衡性，尽管单语言索引可在对应语言的单项结果上领先。这些结果支持将混合检索作为铁路领域大语言模型的知识访问机制 (Robertson and Zaragoza, 2009; Cormack et al., 2009)。

这一增益伴随计算成本。混合检索时延约为 BM25 的三倍，增加段落数量也可能扩大生成上下文。不过，图 2 表明，在固定候选池下把最终截断点从 top-1 提高到 top-8，可以提升证据召回而几乎不改变检索时延，从而可依据上下文预算调节证据覆盖范围。

5.2 低资源领域适配的有效性

仅答案监督的 QLoRA 在两种模型和两种语言上均提高了留出铁路问答表现，其中 Qwen2.5-7B 的增益最强且最均衡，并在加入混合证据后达到最高 Answer F1。生成器矩阵还表明，审批混合 RAG 相对无检索条件提高了每个受评估模型和语言的 Answer F1。由此可见，检索知识和参数适配提供不同且互补的增益：检索改善所有生成器，QLoRA 则使中等规模 Qwen 模型取得最强的铁路问答绝对结果。

这一差异对于垂直领域模型具有实际意义。更大的未适配参考模型不能替代铁路证据访问或目标领域适配；适配本身也不自动保证正确的证据归因。Qwen QLoRA 对检索段落保持较高语义支持，但引用标签覆盖较弱，说明答案质量与可见归因需要不同的优化目标。

5.3 资源—质量权衡与局限

所有受评估模型均在 24 GB GPU 边界内运行，说明无需多 GPU 训练即可实施该方法。图 4 同时显示了明确的权衡：Qwen QLoRA 提供最强问答质量，但比原始模型使用更多预留显存和生成时间。GLM QLoRA 同样增加显存占用，其异常短输出意味着较低实测时延不能解释为有效效率优势。因此，实验支持本地可行性，但不意味着领域适配没有计算成本。

本研究限于一个冻结语料划分、一个 epoch 和一个主要随机种子。样本层面的显著性检验不能测量重复训练之间的变异，证据等价召回也依赖预先定义的匹配规则。适配模型的引用格式遵循仍需改进。这些边界限制了结论的外推范围，但不改变主要观察：在本实验资源约束下，混合证据检索与 QLoRA 共同提高了铁路领域问答表现。

6 结论

本文面向双语铁路职业教育，在单工作站资源约束下构建知识增强型铁路垂直领域大语言模型。BM25 与 BGE-M3 提供互补排序，倒数排名融合在两种语言上均取得最高 Evidence Recall@5；仅答案监督的 QLoRA 显著提升留出铁路问答，其中 Qwen2.5-7B 获得最强的均衡适配结果。加入混合证据后，每个受评估生成器和语言的 Answer F1 均有所提高。结果表明，无需多 GPU 训练，中等规模模型也可以同时增强领域知识访问和铁路专用问答能力。引用行为和重复训练验证仍需进一步加强，但不改变已观察到的检索与铁路问答增益。

参考文献

- Barnett, S., Brannelly, Z., Kurniawan, S., and Wong, S. (2024). Fine-tuning or fine-failing? debunking performance myths in large language models. *arXiv preprint arXiv:2406.11201*. Available at: <https://arxiv.org/abs/2406.11201>.
- Chang, Y., Wang, X., Wang, J., Wu, Y., Yang, L., Zhu, K., Chen, H., Yi, X., Wang, C., Wang, Y., Ye, W., Zhang, Y., Chang, Y., Yu, P. S., Yang, Q., and Xie, X. (2024). A survey on evaluation of large language models. *ACM Transactions on Intelligent Systems and Technology*, 15(3):1–45. DOI: <https://doi.org/10.1145/3641289>.
- Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., and Liu, Z. (2024). Bge m3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. *arXiv preprint arXiv:2402.03216*. Available at: <https://arxiv.org/abs/2402.03216>.
- Cormack, G. V., Clarke, C. L. A., and Buettcher, S. (2009). Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference*, pages 758–759. DOI: <https://doi.org/10.1145/1571941.1572114>.
- Dettmers, T., Pagnoni, A., Holtzman, A., and Zettlemoyer, L. (2023). Qlora: Efficient finetuning of quantized llms. In *Advances in Neural Information Processing Systems*, volume 36. Available at: <https://arxiv.org/abs/2305.14314>.
- Ding, N., Qin, Y., Yang, G., Wei, F., Yang, Z., Su, Y., Hu, S., Chen, Y., Chan, C.-M., and Chen, W. (2023). Parameter-efficient fine-tuning of large-scale pre-trained language models. *Nature Machine Intelligence*, 5(3):220–235. DOI: <https://doi.org/10.1038/s42256-023-00626-4>.
- GLM Team (2024). Chatglm: a family of large language models from glm-130b to glm-4 all tools. Available at: <https://arxiv.org/abs/2406.12793>.
- Huang, L., Liu, Z., Yu, C., Zhu, T., and Yan, B. (2026). Emergency operation scheme generation for urban rail transit train door systems using retrieval-augmented large language models. *Sensors*, 26(6):2006. DOI: <https://doi.org/10.3390/s26062006>.
- Hübscher, G., Geist, V., Auer, D., Hübscher, N., and Küng, J. (2021). Representation and presentation of knowledge and processes – an integrated approach for a dynamic communication-intensive environment. *International Journal of Web Information Systems*, 17(6):669–697. DOI: <https://doi.org/10.1108/IJWIS-03-2021-0031>.
- Kasneci, E., Sessler, K., Küchemann, S., Bannert, M., Dementieva, D., Fischer, F., Gasser, U., Groh, G., Günnemann, S., Hüllermeier, E., Krusche, S., Kutyniok, G., Michaeli, T., Nerdel, C., Pfeffer, J., Poquet, O., Sailer, M., Schmidt, A., Seidel, T., Stadler, M., Weller, J., Kuhn, J., and Kasneci, G. (2023). Chatgpt for good? on opportunities and challenges of large language models for education. *Learning and Individual Differences*, 103:102274. DOI: <https://doi.org/10.1016/j.lindif.2023.102274>.

- Lahnalampi, A. (2024). Utilizing large language models in rail design projects. Master’s thesis, Aalto University. Available at: <https://aaltodoc.aalto.fi/items/87b7ac34-756c-4db2-8bea-f9b9e6b453ed>.
- Lawrence, M., Bullock, R., and Liu, Z. (2019). *China’s High-Speed Rail Development*. World Bank, Washington, DC. DOI: <https://doi.org/10.1596/978-1-4648-1425-9>.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-T., Rocktäschel, T., Riedel, S., and Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474. Available at: <https://arxiv.org/abs/2005.11401>.
- Li, J., Li, C., Niu, S., and Dai, B. (2024). Rschat: intelligent question answering model for railway safety knowledge. In *2024 IEEE/ACIS 24th International Conference on Computer and Information Science*, pages 55–60. DOI: <https://doi.org/10.1109/ICIS61260.2024.10778327>.
- Li, Y., Chen, J., Luo, X., and Zheng, H. (2025). Intelligent human-computer interactive training assistant system for rail systems. *High-speed Railway*, 3(1):64–77. DOI: <https://doi.org/10.1016/j.hspr.2025.02.001>.
- Luo, Y. C., Xun, J., Wang, W., Zhang, R. Z., and Zhao, Z. C. (2025). A driver advisory system based on large language model for high-speed train. Available at: <https://arxiv.org/abs/2501.07837>.
- Lv, K., Yang, Y., Liu, T., Guo, Q., and Qiu, X. (2024). Full parameter fine-tuning for large language models with limited resources. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*, pages 8187–8198. DOI: <https://doi.org/10.18653/v1/2024.acl-long.445>.
- Qwen Team (2024). Qwen2.5 technical report. Available at: <https://arxiv.org/abs/2412.15115>.
- Qwen Team (2025). Qwen3 technical report. Available at: <https://arxiv.org/abs/2505.09388>.
- Robertson, S. and Zaragoza, H. (2009). The probabilistic relevance framework: Bm25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389. DOI: <https://doi.org/10.1561/15000000019>.
- Schwartz, R., Dodge, J., Smith, N. A., and Etzioni, O. (2020). Green ai. *Communications of the ACM*, 63(12):54–63. DOI: <https://doi.org/10.1145/3381831>.
- Song, Y., Tang, Y., and Liu, R. (2025). Large language model and application for railway track management based on domain specialization. In *The Proceedings of the 11th International Conference on Traffic and Transportation Studies*, volume 616, pages 194–204. DOI: https://doi.org/10.1007/978-981-97-9644-1_21.
- Tian, K., Mitchell, E., Yao, H., Manning, C., and Finn, C. (2024). Fine-tuning language models for factuality. In *International Conference on Learning Representations*. Available at: https://proceedings.iclr.cc/paper_files/paper/2024/hash/c361ae924c23cafca6033610d25dbc65-Abstract-Conference.html.

- UNESCO (2023). Guidance for generative ai in education and research. Available at: <https://unesdoc.unesco.org/ark:/48223/pf0000386693>.
- Wandelt, S., Zheng, C., Wang, S., Liu, Y., and Sun, X. (2024). Large language models for intelligent transportation: a review of the state of the art and challenges. *Applied Sciences*, 14(17):7455. DOI: <https://doi.org/10.3390/app14177455>.
- Wang, H. and Li, Y.-F. (2024). Large-scale language models for phm in railway systems: potential applications, limitations, and solutions. In *Proceedings of the 6th International Conference on Electrical Engineering and Information Technologies for Rail Transportation*, volume 1137, pages 591–599. DOI: https://doi.org/10.1007/978-981-99-9311-6_59.
- Wang, L., Chen, S., Jiang, L., Pan, S., Cai, R., Yang, S., and Yang, F. (2025). Parameter-efficient fine-tuning in large language models: a survey of methodologies. *Artificial Intelligence Review*, 58(8):227. DOI: <https://doi.org/10.1007/s10462-025-11236-4>.
- Xu, F. (2018). Future of high-speed railway and university education. In *The Belt and Road*, pages 167–183. Springer, Singapore. DOI: https://doi.org/10.1007/978-981-13-1105-5_7.
- Zheng, O., Abdel-Aty, M., Wang, D., Wang, C., and Ding, S. (2023). Trafficsafetygpt: tuning a pre-trained large language model to a domain-specific expert in transportation safety. Available at: <https://arxiv.org/abs/2307.15311>.